
Systematische Literaturrecherche zur Integration von Resilienz in die autonome Produktionssteuerung

Systematic literature review on the integration of resilience into autonomous production control

Bachelorthesis

Autor: Alexander Decher

Matrikelnummer: 2963802

Betreuer: Leonie Meldt, M. Sc. | Prof. Dr.-Ing. Joachim Metternich

Abgabe: Darmstadt, 14.02.2024



TECHNISCHE
UNIVERSITÄT
DARMSTADT



**Bachelorthesis
für
Alexander Decher | 2963802**



TECHNISCHE
UNIVERSITÄT
DARMSTADT

Thema:

Systematische Literaturrecherche zur Integration von Resilienz in die autonome Produktionssteuerung

Topic:

Systematic literature review on the integration of resilience into autonomous production control



Institut für Produktionsmanagement,
Technologie und Werkzeugmaschinen

Fachbereich Maschinenbau

Otto-Berndt-Str. 2
64287 Darmstadt

Telefon: 06151 16-20080
Telefax: 06151 16-20087

Industrie 4.0 zielt darauf ab, den Produktionsprozess durch Digitalisierung und Dezentralisierung zu optimieren. Künstliche Intelligenz (KI) ermöglicht die autonome Verarbeitung großer Datenmengen aus dem Produktionsprozess, die andernfalls ungenutzt blieben. Insbesondere das Teilgebiet des Machine Learnings (ML) innerhalb der KI bietet das Potenzial, kostengünstigere und ressourcenschonende Herstellungsprozesse zu gestalten. Um dieses Potenzial auszuschöpfen, muss der ML-Ansatz jedoch auch in Störsituationen die geforderten Zielgrößen (z.B. Produktivität, Durchlaufzeit) erreichen. Dies erfordert die Fähigkeit, Störungen zu antizipieren, frühzeitig zu erkennen, darauf zu reagieren und ihre Auswirkungen abzumildern. Diese Eigenschaft, die es ermöglicht, nach dem Auftreten einer Störung rasch in den gewünschten Zustand zurückzukehren, wird als Resilienz bezeichnet und ist zentral für autonome Produktionsprozesse.

Das Ziel dieser Arbeit besteht darin, mittels einer systematischen Literaturrecherche bereits bestehende Ansätze zur resilienten, autonomen Produktionssteuerung zu identifizieren. Fokussiert werden dabei solche, die auf ML-basierten Algorithmen fußen.

Schlussendlich sollen hierdurch potenzielle Forschungslücken aufgedeckt werden, die die Grundlage für zukünftige Forschungsarbeiten bilden könnten.

Die Arbeit enthält folgende Arbeitspunkte:

- Einlesen in die autonome Produktionssteuerung
- Einlesen in das Thema der Resilienz im Produktionskontext, insb. Wertstrom
- Einarbeitung in verschiedene Methoden der systematischen Literaturrecherche
- Konzeptionierung einer eigenen Methodik
- Durchführung der Recherche
- Dokumentation der Ergebnisse

Beginn: 15.11.2023
Umfang: 12CP, 360h
Betreuer: Leonie Meldt M.Sc.


Prof. Dr.-Ing. J. Metternich



Abgabe Abschlussarbeiten

Studierende des Wirtschaftsingenieurwesens/Wirtschaftsinformatik (B.Sc./M.Sc.)

Fachbereich Rechts- und Wirtschaftswissenschaften | Studienbüro

1. Angaben zur Person und Studium

Name: Decher
Vorname: Alexander

Matrikelnr.: 2963802
Studiengang: WI-MB

2. Thema/Titel

Ausgabedatum:	15.11.2023	Abgabedatum:	14.02.2024
---------------	------------	--------------	------------

Titel der Bachelorthesis oder Masterthesis:

Systematische Literaturrecherche zur Integration von Resilienz in die autonome Produktionssteuerung

3. Betreuung / Begutachtung

Fachbereich und Fachgebiet: FB 16 Maschinenbau, PTW

1. Prüfer*in (Titel, Name, Vorname): Prof. Dr.-Ing. Joachim Metternich

2. Prüfer*in (nur bei 2. Versuch | Titel, Name, Vorname)

4. Erklärung zur Abschlussarbeit gemäß § 22 Abs. 7 APB der TU Darmstadt

Hiermit erkläre ich, dass ich die vorliegende Arbeit gemäß § 22 Abs. 7 APB TU Darmstadt selbstständig, ohne Hilfe Dritter und nur mit den angegebenen Quellen und Hilfsmitteln angefertigt habe. Ich habe mit Ausnahme der zitierten Literatur und anderer in der Arbeit genannter Quellen keine fremden Hilfsmittel benutzt. Die von mir bei der Anfertigung dieser wissenschaftlichen Arbeit wörtlich oder inhaltlich benutzte Literatur und alle anderen Quellen habe ich im Text deutlich gekennzeichnet und gesondert aufgeführt. Dies gilt auch für Quellen oder Hilfsmittel aus dem Internet. Diese Arbeit hat in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde vorgelegen. Mir ist bekannt, dass im Falle eines Plagiats (§38 Abs.2 APB) ein Täuschungsversuch vorliegt, der dazu führt, dass die Arbeit mit 5,0 bewertet und damit ein Prüfungsversuch verbraucht wird. Abschlussarbeiten dürfen nur einmal wiederholt werden.

Darmstadt, 12.02.2024

Ort, Datum

Unterschrift Studierende*r

⇒ Diese Selbständigkeitserklärung (inklusive Originalunterschrift des/der Verfasser(s)*in muss auch Bestandteil der Printexemplare der Abschlussarbeit sein. Vorlage -> www.tu-darmstadt.de -> Studieren -> Studierende -> Studienorganisation und TUCaN -> Hilfe und FAQ

Kurzfassung & Abstract

Stichwörter: Resilienz, Produktionssteuerung, Wertstrom

In dieser Arbeit zum Thema Resilienz in der autonomen Produktionssteuerung werden auf Basis einer systematischen Literaturrecherche Methoden zur Integrierung von Resilienz in moderne Produktionssysteme in der aktuellen Fachliteratur analysiert. Dabei werden die Definition und Evaluation von Resilienz untersucht sowie die Nutzung des Begriffs Resilienz in wissenschaftlichen Arbeiten zum Thema Produktion erörtert. Darüber hinaus gilt ein Kapitel der Aufstellung prototypischer Modelle, welche die Nutzung von Methoden zur resilienten Autonomisierung von Steuerungsaufgaben in den Gebieten Maintenance, Scheduling und Dispatching darlegen. In diesem Zuge werden die Validierung und der Praxisbezug der in den Arbeiten aufgestellten Modelle betrachtet. Daraufhin erfolgt eine Analyse aktueller Trends in der Entwicklung der Systemarchitektur von autonomen Produktionssystemen und deren resiliente Ausgestaltung. Abschließend werden auf Basis der analysierten Arbeiten Lücken in der aktuellen Literatur identifiziert und mögliche Forschungsrichtungen für zukünftige Projekte entwickelt.

Inhaltsverzeichnis

SYSTEMATISCHE LITERATURRECHERCHE ZUR INTEGRATION VON RESILIENZ IN DIE AUTONOME PRODUKTIONSSTEUERUNG	I
KURZFASSUNG & ABSTRACT	I
INHALTSVERZEICHNIS	II
ABBILDUNGSVERZEICHNIS	IV
1 EINLEITUNG	1
2 GRUNDLAGEN.....	2
2.1 Wertstrom	2
2.1.1 Wertstrom und Wertstromrisiken	2
2.1.2 Resilienz des Wertstroms.....	3
2.2 Produktionsplanung und Steuerung	4
2.2.1 Produktionssystem.....	5
2.2.2 Datenintegration und Digitale Modelle	6
2.2.3 Autonomisierte Production Planning and Control.....	6
2.3 Machine Learning.....	8
3 METHODIK.....	10
3.1 Suchkriterien.....	10
3.1.1 Datenbanken	10
3.1.2 Keywords.....	10
3.2 Durchführung und Auswahl	11
3.3 Literaturübersicht.....	12
4 LITERATURANALYSE	14
4.1 Maintenance	14
4.2 Scheduling & Dispatching	17
4.3 Systembetrachtung	21

5 LITERATURSYNTHESE	29
5.1 Betrachtung von Resilienz.....	29
5.1.1 Bezug auf Resilienz und ihre Komponenten	29
5.1.2 Definitionen.....	30
5.1.3 Normung, Messung und Bewertung von Resilienz	31
5.2 Aktueller Stand der Technik in Production Planning and Control.....	33
5.2.1 Maintenance	34
5.2.2 Scheduling & Dispatching.....	35
5.2.3 Systembetrachtung	37
5.3 Lücken und Forschungsrichtungen	41
5.3.1 Lücken und Forschungsrichtungen	41
5.3.2 Ausblick Forschung.....	41
6 ZUSAMMENFASSUNG	43
LITERATURVERZEICHNIS.....	VII

Abbildungsverzeichnis

Abbildung 1 - Auswahlschema	11
Abbildung 2 - Bewertungsschema.....	13

1 Einleitung

In einer zunehmend dynamischen und komplexen industriellen Umgebung stehen Unternehmen vor der Herausforderung, ihre Produktionsprozesse effizienter und widerstandsfähiger zu gestalten. Die Integration von Resilienz und Machine Learning in die autonome Produktionssteuerung bietet vielversprechende Lösungsansätze, um diesen Anforderungen gerecht zu werden.

Über die normale Umgebung des Unternehmens heraus sind Produktionssysteme durch ihren globalisierten Charakter, globale Krisen wie Pandemien oder Kriege und Umweltkatastrophen diversen Risiken für die Aufrechterhaltung ihrer Produktion ausgesetzt.

Die Resilienz eines Systems ist hierbei ein zentraler Charakter eines Produktionssystems, welcher oft mit Robustheit oder der Anpassungsfähigkeit eines Systems in Störungssituationen assoziiert wird. Neben Methoden, welche Resilienz in einem Produktionssystem schaffen können, geht diese Arbeit intensiv auf die Definition des Begriffs, seine Kernelemente und Möglichkeiten der Evaluierung von Resilienz ein.

Die Verfügbarkeit von Daten, welche im Produktionsprozess durch die Integration von Technologien aus der vierten industriellen Revolution stammen gesammelt werden können, bieten das Potenzial für die Autonomisierung und Anpassung von Produktionsprozessen für mehr Effizienz und Resilienz. Dabei wird über die erfassende Sensorik hinaus auf Technologien wie dem Digital Twin oder Machine Learning aufgebaut, welche ein zentraler Teil dieser Arbeit sind.

Über die Grundlagen dieser Technologien hinaus stellt diese Arbeit auf Basis einer systematischen Literaturrecherche den aktuellen Stand der Technik für die Steigerung von Resilienz in autonomen Produktionssystemen vor. Hierbei wird die Verwendung von Methoden zur Integration von Maintenance, Scheduling und Dispatching Aufgaben in autonome Steuerungssysteme vorgestellt. Des Weiteren wird eine Betrachtung theoretischer Modelle vorgenommen, welche Resilienz vor dem Hintergrund der allgemeinen Systemarchitektur beleuchten.

Die für diese Arbeit relevanten Forschungsfragen lassen sich damit also wie folgt definieren:

- Wie lässt sich laut der aktuellen Literatur die autonome Produktionssteuerung resilenter machen?
- Inwiefern betrachten die Autoren bei der Entwicklung ihrer Modelle die Resilienz des Systems?

2 Grundlagen

Diese systematische Literaturrecherche beschäftigt sich mit der Ausgestaltung resilenter Wertströme in autonomen Produktionsumgebungen. Dieses Kapitel bearbeitet die theoretischen Grundlagen der Recherchethemen und ist in drei Teile gegliedert. Der erste Teil legt die Theorie des Wertstroms dar und bildet die Grundlage für den hier verwendeten Resilienzbegriff, während der zweite Teil auf die Produktionssteuerung und -planung eingeht. Hierbei werden moderne Produktionssysteme sowie Techniken zur Integration von Daten und deren Verarbeitung und die Hintergründe resilenter Produktionssteuerung erklärt. Der dritte Teil behandelt Grundlagen künstlicher Intelligenz, also die Darlegung von Methoden des Machine Learnings sowie mögliche Anwendungen zur Produktionssteuerung.

2.1 Wertstrom

2.1.1 Wertstrom und Wertstromrisiken

Der Wertstrom bezeichnet den Fluss von Werten in einem Unternehmen und wird von Steinmeyer und Metternich (2023, S. 605) folgendermaßen definiert: „Ein Wertstrom umfasst alle Aktivitäten, um aus Rohmaterial ein fertiges Produkt herzustellen und dem Kunden zu übergeben.“ Neben dem physischen Herstellungsprozess des Produkts betrifft er auch die notwendige Logistik sowie Informationsflüsse im Unternehmen und alle weiteren Elemente der Wertschöpfung. Der Begriff entstammt aus dem Bereich des Lean-Management und eine Analyse des Wertstroms kann dazu genutzt werden, um Abläufe im Wertschöpfungsprozess zu verbessern und zu verschlanken. Ein klassisches Analysetool ist das Value Stream Mapping oder auf Deutsch die Wertstrommethode, welche in DIN ISO 22468 definiert ist. Hierbei wird eine Übersicht über die Aktivitäten, die der Wertstrom enthält, erstellt. Auf dieser Basis erstellt man eine Karte, welche alle Flüsse von Informationen und Materialien im Prozess darstellt. Diese Karte kann dazu genutzt werden, um Engpässe, Verschwendungen oder andere Ineffizienzen aufzudecken und ein verbessertes Modell des Prozesses zu erstellen.

Der Wertstrom eines Unternehmens ist ein komplexes System, welches unter Einflüssen seiner Umwelt agieren muss. Hierbei wirken externe Faktoren wie Kriege und andere Krisen, Preisschocks oder Sanktionen sowie unternehmensinterne Einflüsse auf den Wertschöpfungsprozess ein und können diesen stören. Der Wertstrom unterliegt somit diversen Risiken, welche Steinmeyer und Metternich (2023, S. 606) in Anlehnung an Christopher und Peck (2004) in Prozess-, Nachfrage-, Angebots-, Steuerungs- und das Umweltrisiko unterteilen. Diese Unterteilung wird im Folgenden wiedergegeben und erklärt.

Das Umweltrisiko betrachtet Faktoren in der Umwelt des Unternehmens, wie zum Beispiel Gesetzgebungen oder den Arbeitsmarkt. Ein ausgeprägter Fachkräftemangel oder staatliche Regularien wie bei der Einschränkung oder dem Verbot bestimmter Stoffe, welche das Unternehmen zur Produktion nutzt. Gewissermaßen beeinflusst das Umweltrisiko die vier anderen Arten des Wertstromrisikos mit.

Das Angebotsrisiko beschreibt Risiken, welche von der Lieferantenseite der Lieferkette ausgehen. Diese können durch Embargos, Kriege oder Naturkatastrophen, welche die Lieferkette stören, hervorgerufen werden und eine Verknappung von Ressourcen sowie meist eine damit einhergehende Verteuerung bewirken. Dadurch kann die Produktion des Unternehmens verlangsamt oder gar gestoppt werden.

Bei dem Nachfragerisiko geht es um die andere Seite der Lieferkette, welche durch die Nachfrage der Produkte von anderen Unternehmen oder Konsumenten beeinflusst wird. Hier kann das produzierende Unternehmen ähnlich dem Angebotsrisiko von Störungen in der Lieferkette an sich betroffen sein, wird aber auch durch sich ändernde Präferenzen der Konsumenten am Markt beeinflusst.

Das Steuerungs- und Prozessrisiko sind interne Risiken, die den Ausfall von Maschinen, Netzwerken, Programmen oder Arbeitskräften beschreiben. Auf diese Risiken wird in dieser Arbeit besonders eingegangen, da sie die Umgebung, in der die Production Planning and Control arbeitet, beschreiben. Risiken der Nachfrage und des Angebots werden in der Production Planning and Control auch beachtet, jedoch richten sie sich eher auf die Charakterisierung der Lieferkette aus.

2.1.2 Resilienz des Wertstroms

Der Umgang und die Prävention der oben genannten Risiken sind essenziell für den Ablauf in einem produzierenden Betrieb. Zur Identifikation kann die bereits erwähnte Wertstrommethode genutzt werden, während es zur Bewältigung von Risiken genormte Vorgehensweisen wie in der DIN ISO 31000:2018-10 gibt. Unabhängig von der Methodik ist der Umgang mit Risiken als ein Teil der Resilienz eines Produktionssystems zu verstehen (Sheth und Kusiak 2022). Resilienz in der Produktionsumgebung besitzt keine genormte Definition, weshalb sich in der Literatur viele verschiedene Definitionen von Resilienz finden lassen. Oft werden auch Begriffe wie Robustheit, Agilität oder Flexibilität scheinbar synonym zu Resilienz verwendet. Daher werden im folgenden Abschnitt Ansätze zur Definition dieser Begriffe vorgestellt.

Robustheit bezeichnet die Fähigkeit, stabil gegenüber von außen einwirkenden Kräften oder Veränderungen zu sein und diese ohne wesentliche Beeinträchtigung zu überstehen. Im Wertstromkontext lässt sich dies so deuten, dass das System durch eingetretene Risiken wenig tangiert wird und seine Funktionalität nicht eingeschränkt wird. Agilität beschreibt die Fähigkeit von Organisationen oder Systemen, sich schnell an Schwankungen anzupassen oder flexibel auf Änderungen zu reagieren. In Bezug auf ein produzierendes Unternehmen wäre dies mit modularen Produktionsstätten denkbar, welche schnell auf Änderungen der eingegangenen Bestellungen, Lieferzeiten oder andere Situationen reagieren können. Im normalen Sprachgebrauch wird Resilienz meistens aus dem psychologischen Blickfeld genutzt und als Widerstandsfähigkeit gegen äußere Einflüsse verstanden. Nach Leng et al. 2023) ist Resilienz in Bezug auf Produktionssysteme die Fähigkeit, einen stabilen Zustand unter Einfluss von Stress oder Störungen zu halten oder schnell wiederherzustellen. Eine andere Definition liefert die Deutsche Akademie der Technikwissenschaften e.V. mit der „Fähigkeit, tatsächlich oder potenziell widrige Ereignisse vorherzusehen und einzukalkulieren, ihr Auftreten frühzeitig zu erkennen und deren Entstehen zu verhindern, ihre Intensität abzumildern, ihre Schäden zu dämpfen, sich schnell

davon zu erholen und sich ihnen erfolgreich anzupassen und daraus zu lernen.“ (Johann-Dietrich Wörner und Christoph M. Schmidt 2022, S. 8). Über diese Definition spannen Steinmeyer und Metternich (2023) mithilfe der oben genannten Wertstromrisiken den Bogen zu einer Definition von Resilienz aus der Wertstromperspektive, welche lautet:

„Wertstromresilienz ist die Fähigkeit eines Wertstroms, die Kundennachfrage auch bei Störungen zu befriedigen bei gleichzeitiger Einhaltung der gesetzten Ziele in den Dimensionen Flexibilität, Qualität, Produktivität und Durchlaufzeit, indem Störungen vorhergesehen und einkalkuliert, frühzeitig erkannt, verhindert und abgemildert werden. Je resilenter ein Wertstrom ist, desto schneller erfüllt er nach dem Eintritt einer Störung wieder die gesetzten Ziele und passt sich an die neuen Rahmenbedingungen an.“ (Steinmeyer und Metternich 2023, S. 607)

Diese Definition unterscheidet sich zu anderen in mehreren Punkten. Ein erster wäre hierbei das Einbeziehen der Fähigkeit, sich an neue Rahmenbedingungen anzupassen. Diese Fähigkeit kann man im allgemeinen als Adaptivität bezeichnen. Darüber hinaus gehen Steinmeyer und Metternich (2023) in ihrer Definition auf eine Vorhersage von Störungen ein, die die Resilienz eines Systems ausmachen soll. Dies übersteigt den Umfang weit verbreiteter Definitionen von Resilienz, auf die im Laufe dieser Arbeit noch genauer eingegangen werden sollen, um einiges, da diese sich meist auf die Zielgrößen Agilität und vor allem Robustheit, welche in einigen Fällen als Synonym für Resilienz genutzt wird, beziehen. Viel eher kann man die Begriffe Agilität und Robustheit als Bestandteile von Resilienz verstehen (Mukherjee et al. 2022). Die Begriffe sind also nicht synonym, haben jedoch große Überschneidungen mit der Resilienz und tragen jeweils zu einer Resilienzsteigerung des Wertstroms bei. Somit lassen sich die Zielgrößen der Resilienz in Robustheit, Agilität und Adaptivität gliedern.

Da es sich bei der Produktionsumgebung um einen Teil des Wertstroms handelt, ist es passend, die bereits angeführte Definition auch auf diese anzuwenden. Somit entspricht dies der Definition und den verfolgten Zielgrößen von Resilienz, auf die sich die Inhalte dieser Arbeit beziehen.

2.2 Produktionsplanung und Steuerung

Unter dem englischen Begriff Production Planning and Control versteht man in der deutschen Sprache Produktionsplanung und -steuerung. Diese erstreckt sich sowohl über den Bereich der unmittelbaren Produktion, was zum Beispiel Maschinenzeiten und Wartung betrifft als auch über umliegende Bereiche wie Auftragsein- und Ausgänge, Materialfluss und Qualitätskontrolle. Production Planning and Control ist somit ein zentrales Mittel, um die Effizienz und Funktionalität von zumindest einem Teil des Wertstroms zu gewährleisten, welchem sich diese Arbeit widmen wird. Die Effizienzsteigerung in der Produktion richtet sich meist nach Lean-Prinzipien, welche ihren Ursprung in einem Produktionssystem von Toyota aus dem letzten Jahrhundert haben. Der Begriff Lean Production beschreibt ein System, welches kontinuierlich verbessert wird und eine Reduktion von Verschwendungen sowie einen stabilen Fluss in der Produktion anstrebt. In aktueller Literatur vorkommende Forschungen betreffen oft die Integration von Lean Prinzipien oder Resilienz in sogenannten Job Shops, Flow Shops oder Zellenfertigungen. Auf den Aufbau dieser Produktionssysteme, Ansätze der Steuerung und die Autonomisierung dieses Prozesses

durch die Integration von Datenströmen aus dem Produktionsprozess in digitale Modelle wird in dem folgenden Unterkapitel eingegangen.

2.2.1 Produktionssystem

Der Aufbau eines Produktionssystems wird darüber definiert, in welcher Form die Produktionslinien organisiert sind und wie diese kontrolliert werden. Dabei gibt es diverse Ansätze wie Job Shops, Flow Shops oder zellenbasierte Fertigung sowie Distributed und Centralized Production Control Systeme. Diese werden im Folgenden kurz erläutert.

Ein Job Shop bezeichnet eine Art der Produktionsumgebung, welche einer Werkstatt- oder Stationsfertigung ähnelt. Im Gegensatz zu einer klassischen Massenfertigung am Fließband, wie sie oft in der Automobilbranche eingesetzt werden, gibt es hier viele Stationen, welche flexibel und unabhängig voneinander agieren können. Produkte können dabei den Job Shop in einer beliebigen Reihenfolge durchlaufen (Parveen und Ullah 2011). Dies ermöglicht eine hohe Varianz sowie einen hohen Individualisierungsgrad der gefertigten Produkte. Aufgrund der hohen Flexibilität im Job Shop sind auch kleine Losgrößen wirtschaftlich zu fertigen. Jedoch bringt diese Produktionsumgebung eine komplexe Steuerung und Planung mit sich und ist nicht gut für Großserienfertigungen geeignet. Zentral ist hierbei die Koordinierung des Produktionsflusses zwischen den einzelnen Maschinen und die gleichmäßige Auslastung dieser.

Ein Flow Shop hat einen dem Job Shop ähnelnden Aufbau jedoch mit einer festgelegten, linearen Reihenfolge der Bearbeitungsstationen (Parveen und Ullah 2011). Alle Teile durchlaufen also denselben Weg in der Produktionsstätte, was die Produktionsumgebung weniger flexibel, aber einfacher zu koordinieren und planen macht als einen Job Shop. So lassen sich größere Serienproduktionen und ein optimierter Materialfluss bei standardisierten Produkten erreichen. Das Augenmerk bei der Planung gilt bei der Planung hier einer gleichmäßigen Auslastung aller Stationen, sodass keine Engpässe im Fluss entstehen, bei der sich die Produktion an einer Station aufstauen würde.

Eine Zellenfertigung zeichnet sich darin aus, dass eine Fertigungseinrichtung in autonome Zellen geteilt werden. Diese Zellen sind dazu geeignet, bestimmte Produktfamilien zu fertigen (Singh 1993) und schnell umgerüstet werden zu können, um agil zwischen ähnlichen Produkten zu wechseln. Die Zellen arbeiten unabhängig voneinander und ermöglichen es auch kleinere Losgrößen wirtschaftlich zu fertigen. Hierbei gibt es diverse Organisationsformen, bei denen vor allem der Fluss zwischen den Zellen eine wichtige Metrik zur Steuerung darstellt.

Bei den Ansätzen zur Kontrolle von Produktionssystemen unterscheidet man im Allgemeinen zwischen Modellen, bei denen Daten zentralisiert (Centralized Production Control) evaluiert und darauf basierend Entscheidungen getroffen werden und solchen, die verteilt (Distributed oder Decentralized Production Control) in vielen lokalen Produktionsanlagen eine dezentrale Entscheidungsfindung verfolgen. Vorteile der Distributed Production Control gegenüber einer Centralized Production Control ist die Aufteilung des Ausfallrisikos sowie schnellere Rechendauern und die individuellere Gestaltung lokaler Systeme (Dilts et al. 1991). Diese Eigenschaften sorgen dafür, dass sich Distributed Production Control Ansätze zur

Integration von Machine Learning in höchst individualisierte, autonome und lokale Produktionssteuerungen eignet. Jedoch bringt eine Centralized Production Control den Vorteil mit sich, dass sie das Treffen von global optimierten Entscheidungen vereinfacht (Brennan und Norrie 2001). Neben den beiden genannten Ansätzen gibt es weitere Konzepte, die versuchen, Vorteile beider Modelle zu vereinen. Auf diese wird im Laufe dieser Arbeit noch genauer eingegangen.

2.2.2 Datenintegration und Digitale Modelle

Die Basis für die Gestaltung resilenter und autonomer Produktionssysteme ist die Integration von Daten, welche klassisch mit Hilfe der in 2.1 erklärten Wertstrommethode analysiert werden können. Der Einzug von Technologien aus der vierten industriellen Revolution ermöglicht einen automatisierten Umgang mit Datenströmen, welche durch die Integration einer Vielzahl von Sensoren erfasst werden können. Durch die Verflechtung des physischen und virtuellen Systems entsteht ein Cyberphysical System, in das Datenströme in Echtzeit integriert werden können. Die Verarbeitung der Daten findet oft in digitalen Modellen wie dem Digital Twin oder dem Digital Shadow statt. Dabei ist der Digital Twin eines der verbreitetsten Modelle und geht wohl auf eine Idee, die bereits Anfang des 21. Jahrhunderts entstanden ist zurück (Michael Grieves 2016). Dabei stellen künstliche Intelligenz und cloudbasierte Technologien Kernkomponenten der automatisierten Integration und Verarbeitung der Daten in digitalen Modellen für moderne Produktionssysteme dar.

Sowohl der Digital Twin als auch der Digital Shadow sind digitale Modelle eines physischen Prozesses. Daten aus dem Prozess werden in Echtzeit in eine dafür entwickelte Software importiert. Daraus ergibt sich eine dauerhaft aktuelle Abbildung des Produktionsprozesses. Durch die Integration vieler Sensoren in Maschinen und sonstigen Produktionsanlagen lässt sich so ein möglichst genaues Modell des realen Prozesses abbilden. Somit lassen sich Maschinen, Produktionsabschnitte oder theoretisch ganze Fabriken und Produktionsnetzwerke als digitales Abbild festhalten. Sie unterscheiden sich insoweit, dass ein Digital Shadow nur als Darstellungsform genutzt wird und nur der Digital Twin einen automatisierten Datenverkehr zurück ins physische Objekt ermöglicht (Frick und Metternich 2022). Die aus einem Digital Shadow oder Digital Twin abgeleiteten Modelle erlauben es, Simulationen am Produktionsprozess durchzuführen, ohne dabei den physischen Prozess zu berühren und somit hohen Aufwand und Kosten zu vermeiden. So lässt sich beispielsweise die Resilienz eines Produktionsprozesses durch die Simulation in Umgebungen mit induzierten Störungen testen. Außerdem kann diese Simulation zur Generierung von Daten genutzt werden, die das Training eines auf Machine Learning basierten Modells erlauben.

2.2.3 Autonomisierte Production Planning and Control

Neben der Steigerung der Effizienz gilt es bei der Production Planning and Control auch Risiken und Gefahren für die Produktion abzuwenden, um eine ungestörte Produktion zu gewährleisten. Die Steuerung des Prozesses muss robust gegenüber den in 2.1 genannten Wertstromrisiken gestaltet werden sowie agil und adaptiv auf veränderte Bedingungen reagieren, somit also resilient gegenüber seiner

Umwelt sein. Zur Gestaltung einer resilienten Produktionsanlage gibt es diverse Möglichkeiten, worunter auch die Autonomisierung der Produktionssteuerung fällt. Dazu zählen zum Beispiel die autonome Anpassung von Wartungsintervallen und Maschinenzeiten oder eine autonome Entscheidungsunterstützung als Schnittstelle zum menschlichen Bediener. Die Autonomisierung selbst trägt dazu bei, den Prozess resilenter zu gestalten, indem sie den menschlichen Entscheidungsanteil minimiert und somit mögliche Fehlerquellen entschärft. Jedoch bietet die Autonomisierungen auch Risiken und gestaltet den Prozess nicht abschließend resilient. Vielmehr gilt es Methoden zu finden, mit denen man Resilienz in die Autonomisierung integriert.

Die Integration von Wartungsmaßnahmen ist ein zentraler Aspekt in produzierenden Betrieben. Maschinen und Werkzeuge degradieren über ihre Betriebsdauer und müssen gewartet oder ausgetauscht werden. Bei der präventiven Wartung von Maschinen unterscheidet man in die zeitbasierte und zustandsbasierte Wartung, die sich nach durch den Hersteller vorgegebenen Zeitintervallen beziehungsweise dem überprüften Zustand des Systems richtet. Eine zustandsbasierte Wartung kann dabei die Wartungsintervalle ausreizen und die Zahl der benötigten Wartungen somit senken. Ihr Ziel ist es, Wartungsmaßnahmen durchzuführen, bevor es zu einer Abnahme der Produktqualität oder einem Versagen des Werkzeugs kommt. Jede durchgeführte Wartungshandlung benötigt einen Stopp des Produktionsprozesses. Hierbei kann die Planung der Maßnahmen durch Machine Learning unterstützt werden, um eine möglichst günstige und automatisierte Integration in den Produktionsprozess zu ermöglichen. Auch kann die Betrachtung des Gesundheitszustands einer Maschine durch Algorithmen und Sensoren automatisiert werden. Diese Methode nennt sich Predictive Maintenance und hat die Vorhersage der Remaining Useful Life (Schwendemann et al. 2021), welche durch die Überwachung von Prozessparametern an der betroffenen Maschine getätigt wird, als Grundlage. Auf die Integration solcher Methoden wird im Laufe der Arbeit genauer eingegangen.

Neben der Integration von Wartung spielen die eigentliche Planung der Produktionspläne eine zentrale Rolle in der Autonomisierung des Produktionsprozesses. Dabei beschreiben die Begriffe Scheduling und Dispatching die Zuweisung von Maschinen oder Arbeitskräften in einen Produktionsplan beziehungsweise der Steuerung und Anpassung des aufgestellten Plans (Kuhnle 2020). Hierbei beschreibt Scheduling einen eher länger- und Dispatching, einen eher kurzfristigen Prozess. Für die globale Optimierung von Produktionsplänen eignen sich hierbei Heuristiken sehr gut, welche oft in Centralized Production Control Ansätzen angewendet werden (Qin und Lu 2021). Auch Machine Learning basierte Ansätze sind hier denkbar, da sie eine höhere Flexibilität und Adaptivität sowie die Möglichkeit zur Selbstanpassung bieten und könnten somit vor allem in dynamischen Job Shop Umgebungen Anwendung finden (Liu et al. 2023). Bei Order Dispatching kommen vor allem Machine Learning basierte Ansätze in Frage, da in diesem Fall Entscheidungen innerhalb weniger Sekunden zu treffen sein können (Sturm 2006). Die Anwendung findet in den lokalen Produktionsstätten statt und ist somit an eine stark dezentralisierte Kontrolle gebunden. Im Laufe der Arbeit wird auf die technische Umsetzung noch detaillierter eingegangen.

2.3 Machine Learning

Machine Learning ist ein wichtiger Zweig im Bereich der künstlichen Intelligenz. Bei maschinellem Lernen werden durch die Nutzung von Algorithmen diverse Modelle entwickelt, die mit Daten trainiert werden können. Im Gegensatz zu traditionell programmierten Software können Machine Learning basierte Modelle dauerhaft aus aktuellen Daten lernen und sich adaptieren, ohne explizit umprogrammiert werden zu müssen. Diese Eigenschaft ordnet sich in die zuvor geschriebenen Komponenten der Resilienz eines Systems ein. Dazu muss zuerst ein Trainingsprozess erfolgen, bei dem sich das Modell seine Verhaltensweisen aneignet. Dabei können unter anderem Daten, welche aus dem Produktionsprozess gewonnen werden, für das Training des Modells genutzt werden. Des Weiteren lassen sich in Simulationen Daten für das Training generieren, was den Vorteil hat, dass diese freier zugänglich sind und in anpassbaren Umgebungen erzeugt werden.

Algorithmen des Machine Learnings umfassen verschiedene Ansätze wie Supervised (überwachtes), Unsupervised (unüberwachtes) und Reinforcement (verstärkendes) Learning (Kuhnle 2020). Nach diesen Gruppierungen lassen sich die meisten Algorithmen einordnen. Im Allgemeinen spricht man bei Machine Learning basierten Modellen meist von einem Agenten und einer Umgebung. Diese lassen sich folgendermaßen einordnen: „The term agent describes a computer system that is embedded in an environment and makes decisions“ (Kuhnle 2020, S. 29). Neben dem Einsatz von einem Agenten in einem System gibt es auch sogenannte Multi Agenten Systeme. Hierbei sind mehrere kooperierende oder konkurrierende Agenten im Einsatz, welche besonders in komplexen Systemen sinnvoll einsetzbar sind.

Im Falle von Supervised Learning wird ein gelabelter Datensatz für das Training verwendet. Darauf basierende Modelle werden meist zum Einsatz für Klassifikationsaufgaben, bei denen der Algorithmus einen Input einer bestimmten Gruppe zuordnen muss, genutzt (Nasteski 2017). Diese Datensätze sind jedoch komplex in der Erstellung und dadurch eher kostenintensiv.

Währenddessen kommen bei Unsupervised Learning Datensätze zum Einsatz, die keine Zuordnung der Informationen besitzen. Diese eignen sich besonders gut zur Gruppierung von Daten und dem Finden von Mustern in diesen. Unter anderem lassen sich diese Algorithmen dazu anwenden, Datensätze für die Nutzung in Unsupervised Learning Algorithmen vorzubereiten (Berry et al. 2020).

Bei Reinforcement Learning handelt es sich um die wahrscheinlich wichtigste Art des Lernens für die in dieser Arbeit vorgestellten Anwendungsfälle. Dabei orientiert man sich an dem verhaltensbiologischen Gebiet der Konditionierung. Dabei wird dem Agenten, welcher auf einer Trial and Error Basis in seiner definierten Umgebung agiert, für sein Verhalten eine positive beziehungsweise negative Rückmeldung gegeben, die schlussendlich die Verhaltensweisen des Systems bestimmt (Kuhnle 2020).

Eine der bekanntesten Funktionen von Machine Learning basierten Programmen ist die Pattern Recognition. Es können große Datenmengen in kurzer Zeit durch MAS analysiert werden und auf der Basis der Ergebnisse autonom Entscheidungen getroffen werden. Diese Daten können aus einem in 2.2 beschriebenen Digital Twin oder Digital Shadow stammen. Im Kontext der PPS können diese Entscheidungen genutzt werden, um den Produktionsprozess autonom anzupassen oder als Entscheidungshilfe für Menschen in der Fertigung zu dienen.

Auf die Anwendung dieser Techniken in konkreten Modellen wird in den folgenden Kapiteln genauer eingegangen. Die verbleibenden Teile dieser Arbeit werden in vier weitere Kapitel geteilt. Kapitel 3 Methodik erörtert hierbei die Entstehung und Anwendung der Methodik, welche dieser Literaturrecherche zugrunde liegt. Im darauffolgenden Kapitel 5 Literaturanalyse werden die Inhalte der recherchierten Literatur ausführlich wiedergegeben. Währenddessen widmet sich Kapitel 6 Literatursynthese der Abstrahierung und Einordnung der recherchierten Inhalte. Diese werden hierbei in prototypische Ansätze für die Aufgaben Maintenance, Scheduling und Dispatching eingegliedert sowie aktuelle Trends zur Entwicklung resilenter Produktionssysteme und deren Modellarchitekturen dargelegt. Kapitel 6 betrifft eine Zusammenfassung der Inhalte dieser Arbeit.

3 Methodik

Die dieser systematischen Literaturrecherche zugrunde liegenden Methodik wird im folgenden Kapitel, welches in drei Unterkapitel gegliedert ist, erörtert. Dabei wird die Entstehung der und der Aufbau der Methodik dargelegt und der eigentliche Auswahlprozess beschrieben. Der erste Abschnitt erklärt die Auswahl der Kriterien, welche zur Suche von Literatur herangezogen werden. Dies beinhaltet die verwendeten Online-Datenbanken und die Keywords, welche den verwendeten Suchstring ausmachen. Der zweite Abschnitt beschäftigt sich mit der Durchführung der Recherche und dem Auswahlprozess der in der Endauswahl enthaltenen Paper. Der letzte Teil stellt die ausgewählte Literatur in einer übersichtlichen Form tabellarisch dar und erklärt die darin enthaltenen Kriterien und Gruppierungen. Die Literaturanalyse, welcher auf dieses Kapitel folgt, gibt einen Überblick über den Inhalt der ausgewählten Arbeiten.

3.1 Suchkriterien

3.1.1 Datenbanken

Im ersten Schritt müssen die Datenbanken, welche in den folgenden Schritten durchsucht werden, festgelegt werden. Dazu wird das Datenbankenverzeichnis DBIS der Universitäts- und Landesbibliothek Darmstadt nach passenden Einträgen in den Bereichen Wirtschaft und Maschinenbau durchsucht. Somit ergeben sich die Eingliederung von WISO, Science Direct, Taylor and Francis sowie Ebsco als Datenbanken, welche in einer Volltextsuche mit dem gleichen Suchstring durchsucht werden.

3.1.2 Keywords

Bei den ausgewählten Keywords wird sich auf die englischen Suchbegriffe beschränkt, da dies die meiste relevante Fachliteratur umfasst. Der Aufbau des Suchstrings ist in drei Teile gegliedert. Der erste Teil umfasst die Resilienz und wird mit den Begriffen „resilient“, „resilience“ und „flexibility“ beschrieben. Die zusätzliche Inklusion von „robustness“ und „agility“ hätte keine große Ausweitung der Suchergebnisse erbracht und wird daher ausgelassen. Der zweite Teil beschreibt die Produktionskomponente dieser Suche und wird mit den Begriffen „production control“, „order dispatching“ und „order control“ repräsentiert. Der dritte Teil ist als Filter zu verstehen und soll mit den Begriffen „machine learning“ und „value stream“ die Suche thematisch weiter eingrenzen. Somit ergibt sich der resultierende Suchstring zu:

(Resilient OR resilience OR flexibility) AND ("production control" OR "order dispatching" OR "order control") AND ("Machine Learning" OR "value stream")

3.2 Durchführung und Auswahl

Die Recherche wird mit dem im letzten Abschnitt dargelegten Parametern im Dezember 2023 durchgeführt und ergibt in der Volltextsuche eine Gesamtzahl von 1088 Treffern. Diese werden daraufhin im Literaturverwaltungsprogramm Citavi gruppiert und schrittweise aussortiert. Dazu werden im ersten Schritt zwölf Duplikate entfernt. Der nächste Schritt im Auswahlprozess filtert die Arbeiten nach ihren Titeln und Keywords. Hierbei werden nur englische und deutsche Arbeiten in Betracht gezogen und alle Arbeiten, die thematisch unpassend sind, aussortiert. Dies betrifft Literatur aus anderen Fachbereichen wie Medizin, Städteplanung oder Bauingenieurswesen. Somit sind im dritten Auswahlschritt nur noch 72 Arbeiten enthalten, welche sich mit der Gestaltung von resilienten Produktionssystemen und deren Architektur auseinandersetzen. Eine Restriktion über das Publikationsdatum wird nur indirekt verwendet, da ein Fokus auf Literatur liegt, die moderne Methoden wie Machine Learning Systeme oder den Digital Twin verwenden. Die verbliebene Menge an Arbeiten wird durch eine Analyse der jeweiligen Abstracts weiter eingeschränkt, sodass 33 thematisch passende Titel zur Volltextanalyse in die vorläufige Endauswahl übernommen werden. Auf zwei Arbeiten besteht kein Volltextzugriff, und fünf weitere werden nach der Analyse als unpassend bewertet, wodurch sie endgültig aus dem Auswahlprozess ausscheiden.

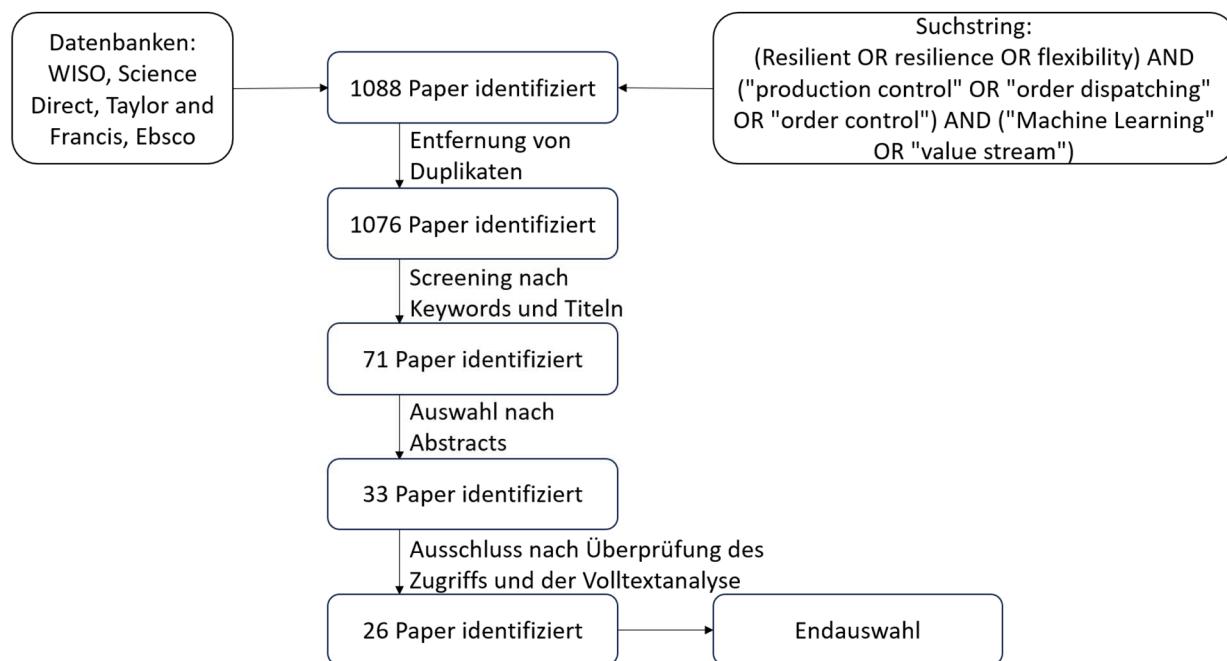


Abbildung 1 - Auswahlschema

3.3 Literaturübersicht

Um einen Überblick über die schlussendlich identifizierte Literatur zu erhalten, wird eine Übersicht erstellt, in der die vorhandenen Arbeiten in verschiedenen Kategorien bewertet werden. In der ersten Kategorie wird dabei die Systemresilienz betrachtet. Dabei wird durch die Option „Resilienzbetrachtung“ bewertet, inwiefern die Resilienz des Systems ein Ziel oder Gedanke der Autoren war. Die Optionen „Robustheit“, „Agilität“ und „Adaptivität“ sollen signalisieren, mit welchen Bestandteilen der Systemresilienz sich die Autoren vor allem auseinandergesetzt haben. Die zweite Kategorie gibt einen Überblick über die in der Literatur verwendete technische Umsetzung. Hierbei stehen die Optionen „Machine Learning“, „Digital Twin / Digital Shadow“ oder „Andere“ zur Verfügung.

In der dritten Kategorie wird der Angriffspunkt betrachtet, welchem sich das jeweilige Paper widmet. In dieser befinden sich die Optionen „Maintenance“ und „Dispatching & Scheduling“, welche sich als gängige Themenschwerpunkte für konkrete Modellansätze bei Production Planning and Control in der Literatur herausstellen. Auch die „Systembetrachtung“ ist eine Option in dieser Kategorie. Hier findet sich Literatur wieder, welche eine holistische oder grundsätzliche Betrachtung von Resilienz schaffenden Maßnahmen in der Produktionssteuerung vornimmt. Dabei wird besonders die Modellarchitektur von modernen Produktionssystemen betrachtet. Nach dieser Kategorie richtet sich auch die thematische Gruppierung der Literatur, welche in den folgenden Kapiteln analysiert werden. Hierbei wird die Literatur in die den Optionen der Kategorie Angriffspunkt gleichnamigen Gruppen „Maintenance“, „Dispatching & Scheduling“ und „Systembetrachtung“ eindeutig zugeordnet. Diese Unterteilung in Schwerpunkte ist nicht abschließend, da einige Paper thematisch in mehrere Gruppen einzuordnen wären. Der Übersichtlichkeit halber ist jedes Paper aber nur einer Gruppe zugehörig.

In der letzten Kategorie wird betrachtet, wie stark die praktische Ausrichtung der vorgestellten Ansätze ist. Hier bewegt sich das Spektrum zwischen theoretischen Modellen ohne eine vorgenommene Validierung und solchen, die eine physische Validierung in Produktionsumgebungen oder an Demonstratoren vornehmen.

Legende:										
	Maintenance	Angriffspunkt	Scheduling & Dispatching	Systembetrachtung	Systemresilienz	Technologie	Machine learning	Digital Twin	Andere	Praxisintegration
Autoren (Jahr)										
Neto, Anis Assad; Carrijo, Bruna Sprea; Romanzini Brock, João Guilherme; Deschamps, Fernando; Lima, Edson Pinheiro de (2021)	●	○	○	○	○	●	○	●	○	●
Zonta, Tiago; Da Costa, Cristiano André; Zeiser, Felipe A.; Oliveira Ramos, Gabriel de; Kunst, Rafael; Da Rosa Righi, Rodrigo (2022)	●	○	○	○	●	○	●	●	○	○
Morariu, Cristina; Morariu, Octavian; Răileanu, Silviu; Borangiu, Theodor (2020)	●	○	○	○	○	●	●	●	○	●
Elbasheer, Mohaiad; Longo, Francesco; Mirabelli, Giovanni; Padovano, Antonio; Solina, Vittorio; Talarico (2022)	●	○	○	●	●	●	●	●	○	●
Maintenance										
Hofmann, Constantin; Krahe, Carmen; Stricker, Nicole; Lanza, Gisela (2020)	○	●	○	○	○	●	●	●	○	●
Greis, Noel P.; Nogueira, Monica L.; Rohde, Wolfgang (2022)	○	●	○	●	●	○	○	●	●	●
Liu, Youshan; Fan, Jiaxin; Zhao, Linlin; Shen, Weiming; Zhang, Chunjiang (2023)	○	●	○	○	●	○	●	●	○	●
Kuhnle, Andreas; Röhrig, Nicole; Lanza, Gisela (2019a)	○	●	○	○	○	●	●	●	○	●
Stricker, Nicole; Kuhnle, Andreas; Sturm, Roland; Friess, Simon (2018)	○	●	○	○	○	●	●	●	○	●
Kuhnle, Andreas; Schäfer, Louis; Stricker, Nicole; Lanza, Gisela (2019b)	○	●	○	○	○	●	●	●	○	●
Scheduling & Dispatching										
Antons, Oliver; Arlinghaus, Julia C. (2021)	○	●	●	●	○	○	○	○	●	●
Sheth, Ananya; Kusiak, Andrew (2022)	○	○	●	●	●	○	●	●	●	○
Qin, Zhaojun; Lu, Yuqian (2021)	○	●	●	●	○	○	●	●	○	○
Peukert, Sina; Hörgen, Moritz; Lanza, Gisela (2023)	○	○	●	●	●	○	○	○	●	●
Paraschos, P. D.; Xanthopoulos, A. S.; Koulinas, G. K.; Koulouriotis, D. E. (2022)	○	●	●	●	●	○	●	●	○	●
Mukherjee, Avik; Giatt, Moritz; Mustafa, Waleed; Kloft, Marius; Aurich, Jan C. (2022)	○	○	●	●	●	○	●	●	○	●
Leng, Jiewu; Zhong, Yuanwei; Lin, Zisheng; Xu, Kailin; Mourtzis, Dimitris; Zhou, Xueliang; Zheng, Pai; Liu, Qiang; Zhao, J. Leon; Shen, Weiming (2023)	○	○	●	●	●	●	●	●	●	○
Hosseini, Seyedmohsen; Al Khaled, Abdullah; Sarder, M. D. (2016)	○	○	●	●	●	●	●	●	●	●
Ehrhardt, Jonas M.; Hoffmann, Christoph T. (2020)	○	○	●	●	●	●	●	●	●	●
Di Orio, Giovanni; Cândido, Gonçalo; Barata, José (2015)	○	●	●	●	●	●	●	●	●	●
Brettel, Malte; Fischer, Felix Gabriel; Bendig, David; Weber, Anja Ruth; Wolff, Bartholomäus (2016)	○	○	●	●	●	●	●	●	●	●
Arzi, Yohan; Herbon, Avi (2000)	○	●	●	●	●	●	●	●	●	●
Möhring, H.-C.; Wiederkehr, P.; Erkorkmaz, K.; Kakinuma, Y. (2020)	○	○	●	●	●	●	●	●	●	●
Klaas, Alexander; Streit, Daniel; Schilling, Markus; Dangelmaier, Wilhelm (2013)	○	○	●	●	●	●	●	●	●	●
Jiewu Leng, Weinan Sha, Zisheng Lin, Jianbo Jing, Qiang Liu; Chen, Xin (2022)	○	●	●	●	●	●	●	●	●	●
Byrne, G.; Damm, O.; Monostori, L.; Teti, R.; van Houten, F.; Wegener, K.; Wertheim, R.; Sammler, F. (2021)	○	○	●	●	●	●	●	●	●	●
Systembetrachtung										

Abbildung 2 - Bewertungsschema

4 Literaturanalyse

In diesem Kapitel der Arbeit wird die im vorangegangenen Kapitel ausgewählte Literatur ausgiebig vorgestellt. Dafür unterteilt sich dieses Kapitel in 3 Unterkapitel, welche sich nach der zuvor vorgestellten Gruppierung der Literatur in die Gruppen Maintenance, Scheduling & Dispatching sowie der Systembetrachtung richten. In diesen wird die vorliegende Literatur inhaltlich wiedergegeben und deren Kernelemente hervorgehoben. Eine inhaltliche Synthese und ein Vergleich der vorgestellten Modelle erfolgen in Kapitel 5 dieser Arbeit.

4.1 Maintenance

Dieses Unterkapitel widmet sich vier Arbeiten, welche im Rahmen des Auswahlprozesses identifiziert und der Gruppe Maintenance zugeordnet werden. Die Autoren beschäftigen sich in ihren Arbeiten mit der Planung von Wartungsmaßnahmen im Rahmen des Produktionsplans. Dabei werden unter anderem Machine Learning und Digital Twin basierte Maßnahmen verwendet, die dazu genutzt werden, über die Integration von Datenströmen aus dem Produktionsprozess die Lebensdauer von Werkzeugen und Maschinen zu bestimmen. Außerdem werden Decision Support Systems entwickelt, die einer Unterstützung oder kompletten Übernahme der Entscheidungsfindung zur Eingliederung von Wartungsmaßnahmen in den Produktionsplan dienen. Durch diese Integration der Produktionsplanung kommt es zu einer inhaltlichen Überschneidung mit behandelten Themen in der Gruppe Scheduling & Dispatching. Dennoch werden die Arbeiten durch ihren besonderen Fokus auf Wartungsmaßnahmen in diese Gruppe eingesortiert.

In der ersten Quelle entwickeln Neto et al. (2021) ein Digital Twin basiertes Decision Support System. Dieses soll dabei helfen, die Kosten eines Produktionsstopps zur präventiven Instandhaltung degradierender Komponenten an Maschinen zu minimieren. Dazu legen die Autoren einen Digital Twin des Produktionsprozesses an. Dieses Modell erfasst den Durchfluss und Bestand an Ressourcen in der Produktionsanlage sowie die Position von Produkten in der Produktionsanlage über Radio Frequency Identification Chips. Genauso erfasst es den aktuellen Betriebszustand der Maschinen. Auf Basis des sich dauerhaft aktualisierenden Digital Twins werden kurzzeitige Simulationen des Produktionsprozesses durchgeführt, welche sich nach dem Discrete Event Simulation Prinzip richten. Diese werden genutzt, um freie Zeiträume im Produktionsablauf zu identifizieren, die sich über den Stopp von Maschinen durch deren Ausfall oder durch andere Gegebenheiten ergeben. Diese Zeiträume wollen die Autoren für eine möglichst kostengünstige Integration von Wartungsmaßnahmen nutzen. Die durch den Digital Twin gewonnenen Erkenntnisse werden durch ein Decision Support System verarbeitet, dessen Aufgabe es ist, eine unterstützende Schnittstelle zur Entscheidungsfindung für den Menschen zu bieten. Sie lehnen das Design des Decision Support Systems an ein standardisiertes „design science research protocol“ an. Dadurch sollen unrealistische Aufwände zur Konstruktion eines solchen Decision Support Systems verringert und damit die praktische Anwendbarkeit des erstellten Modells erhöht werden. Zur Validierung

applizieren die Autoren das System in ein reales Fallbeispiel in der Industrie. Dazu integrieren sie die Parameter eines möbelfertigenden Unternehmens in ihre Softwarelösung und führen damit Testsimulationen durch. Dabei ist das System in der Lage, für jede Maschine die Prozessdauern für Produktionsaufgaben vorherzusagen und basierend auf Pufferkapazitäten und dem Ausfall von Maschinen günstige Zeiträume für die Eingliederung von Wartungsmaßnahmen in den Produktionsprozess zu identifizieren.

Zonta et al. (2022) stellen auf Basis von Remaining Useful Life Vorhersagen ein Modell vor, welches Predictive Maintenance und Scheduling zu einem Gesamtkonzept vereinen soll. Das Ziel ist es, von klassischen, präventiven Wartungsarbeiten abzurücken und durch die Nutzung eines Machine Learning Modells Datenströme aus dem Produktionsprozess zu nutzen. Dies soll eine verlässliche Vorhersage von nötigen Wartungsarbeiten ermöglichen sowie die Integration von Maßnahmen in den Produktionsplan über den Zeitraum von mehreren Tagen erlauben. Eine erste Aufgabe ist hierbei die verlässliche Bestimmung der Remaining Useful Life. Dazu verarbeitet das Machine Learning basierte Modell Datensätze, welche Informationen über Telemetrie und Maschinenausfälle beinhalten. Die Autoren greifen dafür auf einen KI-generierten Datensatz von Microsoft Azure zurück. Dieser eignet sich für das Supervised Learning eines Modells mit einer Klassifizierungsaufgabe, da er Telemetriedaten wie Spannung oder Drehzahl von Maschinen sowie Informationen einer Ausfallsituation von 100 Maschinen enthalten. Das Training mit diesen Daten ermöglicht es dem Modell bestimmte Zustände aus den Telemetriedaten, die im Prozess gewonnen werden, zu nutzen, um daraus Zusammenhänge von Maschinenausfällen zu erkennen. Die Autoren wählen eine Modellarchitektur mit zwei versteckten Schichten aus Deep Neural Networks oder Recurrent Neural Networks und einer Deep Feed Forward Output Schicht. Neben der Integration von Wartungsmaßnahmen in den Produktionsprozess ist der Vergleich von Deep Neural Networks und Recurrent Neural Networks eines der Ziele der Autoren. Die Simulation zeigt, dass sich die Verwendung von Convolutional Neural Networks besser dazu eignet, mit Rauschen in den Datensätzen umgehen zu können. Außerdem sind diese nicht an einen zeitlichen Zusammenhang in den Trainingsdaten gebunden, um daraus tiefgehende Informationen zu extrahieren. Ein wichtiger Schritt zur Erhöhung der Systemleistung ist die Bearbeitung der Datensätze, was unter anderem das Herausfiltern von Rauschen in den Signalen enthält. Hierbei wenden die Autoren Kalmam und Savitzky-Golay Filter zur Glättung der Signale sowie eine Kombination von Degressionsindizes an, was eine deutliche Verbesserung der Vorhersageergebnisse mit sich bringt. Das Modell wird schließlich in Simulationsexperimenten eines Job Shop Scheduling Problems getestet. Hierbei findet die Integration in die Produktionspläne durch die Verwendung der von Google-Developern entwickelten Software OR-Tools statt. Die Ergebnisse der Simulation zeigen, dass das Modell eine verlässliche Vorhersage der Remaining Useful Life von bis zu fünf Tagen vornehmen kann. Auch ist es in der Lage, basierend auf dieser Remaining Useful Life Vorhersage, den Produktionsplan für eine Inklusion der Wartungsarbeiten anzupassen. Ein limitierender Faktor ihrer Arbeit sind laut den Autoren fehlende Produktionsdaten aus einem echten Industrieszenario, welche für die Verbesserung des Modells essenziell wären.

Morariu et al. (2020) erarbeiten in ihrem Paper ein Machine Learning basiertes Modell, für vorrausschauende Wartung und Nutzung von Ressourcen sowie die Minimierung von Produktionskosten. Dabei wird durch den Einsatz von Algorithmen auf allen Ebenen eines globalen Produktionsnetzwerks der Energieverbrauch und die Produktionszeiten prognostiziert. Für diesen Zweck trainieren die Autoren ein neuronales Netzwerk, welches eine Prognose tätigt und diese dann mit dem tatsächlich eintretenden Wert vergleicht. Durch diesen Vergleich ist das neuronale Netzwerk in der Lage, Anomalien zu erkennen. Bei der Erkennung einer Anomalie werden durch den Agenten Schritte zur Einleitung von Wartungsmaßnahmen oder der Anpassung des Produktionsplans eingeleitet. Machine Learning Modelle sind in der Lage, Zustände vorherzusagen sowie Informationen und Daten zu klassifizieren und zu gruppieren. Die Autoren fokussieren sich in ihrer Arbeit auf die Vorhersage von Systemzuständen. Dadurch lassen sich in dieser Anwendung Maschinenausfälle und freie Zeiträume im Produktionsplan prognostizieren. Dies eignet sich zur Integration von Wartungsarbeiten an Zeitpunkten, die minimale oder keine Störungen im Produktionsplan hervorrufen. Dafür nutzen die Autoren eine Unterklasse von Recurrent Neural Networks, die man Long Short Term Memory Netzwerke nennt, welche sich im Vergleich zu anderen Netzwerktypen besser für Vorhersagezwecke eignen sollen. Für das Training des Machine Learning basierten Modells ist die Integration von Daten aus dem Produktionsprozess nötig. Um diese zu gewährleisten, muss die Produktionsumgebung mit Sensoren bestückt werden, sodass ein dauerhafter Strom der benötigten Daten entsteht. Dadurch kann der Datenstrom in Echtzeit für Unsupervised Learning genutzt werden, was es dem System ermöglicht, sich dauerhaft selbst zu adaptieren. Das entwickelte Modell ist laut den Autoren für vielfältige Anwendungen im Produktionsprozess geeignet. In einem Experiment testen sie dabei durch einen „pick and place“-Versuch die Vorhersage und Optimierung des Energieverbrauchs eines Roboterarms. Darin validieren die Autoren die Funktionalität des von ihnen vorgestellten Modells. Darüber hinaus lasse sich derselbe Mechanismus beispielsweise in Job Shop Anwendungen zur Eingliederung von Wartungs- und Planungsmaßnahmen einsetzen, wobei hierfür kein Beleg für Integration eines solchen Systems angeführt wird.

Die Arbeit von Elbasheer et al. (2022) handelt von einem Rahmenkonzept für das Training eines autonomen Decision Support Agenten, welcher Predictive Maintenance in die Production Planning and Control integrieren soll, welches laut den Autoren bis jetzt in der Fachliteratur fehle. Diese Integration soll in der Lage sein, einen Beitrag zur Steigerung der Systemresilienz zu leisten. Die Autoren stellen Prescriptive Maintenance als eine Erweiterung der Predictive Maintenance vor, welche über die Vorhersage der Systemgesundheit hinaus eine Empfehlung für mögliche Handlungsabläufe zum Umgang mit dem Gesundheitszustand des Systems ausgibt. Somit soll Prescriptive Maintenance die Funktionen von Predictive Maintenance und Production Planning and Control in einem Modell vereinen. Der Decision Support Agent interagiert in diesem Modell mit drei Modulen, welche als Smart Maintenance-, Adaptive Production Planning and Control- und Digital Twin Module bezeichnet werden. Das Smart Maintenance Module ist in eine Predictive Maintenance und eine Scheduling Komponente geteilt, welche eine Vorhersage über den Gesundheitszustand des Systems über die Schätzung der Remaining Useful Life ausgeben und diesbezüglich Empfehlungen möglicher Wartungshandlungen vornehmen. Das Adaptive Production Planning and Control Modul liefert dem Decision Support Agent mögliche Production Planning and Control Strategien, die die möglichen Vorschläge des Prescriptive Maintenance Modules integrieren.

Als Basis der Machine Learning integrierten Planung von Wartungsmaßnahmen ist die Erfassung von Daten aus dem Produktionsprozess für das Training des Modells nötig. Zur Integration von Systemparametern aus dem Produktionsprozess wird das Digital Twin Module genutzt, welches eine virtuelle Repräsentation des Produktionsprozesses bietet. Für das Training des Modells nutzen die Autoren Reinforcement Learning. Dabei werden die vom Decision Support Agent vorgeschlagenen Planungsmaßnahmen im Digital Twin simuliert und ausgewertet. Diese Auswertung führt zu einer dauerhaften Anpassung der Güte des Decision Support Agenten. Die Validierung des Modells halten die Autoren in einer Simulation ab, die eine Produktionsumgebung, welche dem Make-to-order und Engineer-to-order Prinzip folgt, repräsentiert. Hierbei kann das vorgestellte Modell die Dispatching und Sequencing Aufgaben der Simulation erfolgreich erfüllen sowie eine Warnung über das Versagen von Komponenten 24 Stunden im Voraus abgeben. Wobei der Decision Support Agent zu Anfang fast zufällige Entscheidung trifft, stellt sich laut den Autoren ein kontinuierlicher Lernprozess ein.

In dieser Gruppe werden einige Ansätze zur resilienten Gestaltung von Entscheidungen zur Wartung von Produktionssystemen vorgestellt, wozu in der Regel Decision Support Agenten zum Einsatz kommen. Dabei bildet die Vorhersage von Systemzuständen und der Remaining Useful Life die Grundlage der Arbeiten. Diese wird daraufhin von den Autoren genutzt, um Wartungsmaßnahmen möglichst effizient in den vorliegenden Produktionsplan einzugliedern und somit die Entscheidungsfindung von Systemoperatoren zu übernehmen oder zu unterstützen. Allgemein erwähnen die vorgestellten Konzepte eine Praxiserprobung in einer realen Industrieanwendung. Lediglich Neto et al. (2021) haben ihr Konzept mit einer Fallstudie in der Möbelindustrie getestet, wobei dieses System einen niedrigeren Autonomisierungsgrad im Vergleich zu den anderen Modellen aufweist. Auch die Erwägung von Resilienz als Ziel der Maßnahmen ist nur bedingt gegeben. Obwohl alle vorgestellten Modelle die Agilität und Robustheit der Systeme steigern, gehen nur Elbasheer et al. (2022) explizit darauf ein, dass diese Maßnahmen zur Steigerung der Resilienz beitragen.

4.2 Scheduling & Dispatching

Dieser Abschnitt des Kapitels widmet sich der Vorstellung jener Arbeiten, welche mit ihren vorgestellten Modellen die Ausgestaltung autonomer Production Planning and Control Systeme betrachten. Diese Systeme arbeiten, vor allem beim Order Dispatching, in einem höchst dynamischen Umfeld, welches hohe Anforderungen für die Agilität und Adaptivität des Systems aufweist. Dabei nutzen die Autoren hauptsächlich Machine Learning basierte Ansätze, um die entstehenden Aufgaben in der Planung und Steuerung des Prozesses autonom und resilient zu gestalten.

Hofmann et al. (2020) stellen in ihrer Arbeit die Hypothesen auf, dass ein Machine Learning basiertes Production Control System besser auf dynamische Änderungen reagieren könne als ein strikt regelbasiertes System sowie, dass eine Erhöhung der Kommunikation zwischen den Agenten zu einer Verringerung der Durchlaufzeit und „blockierten Zustände“ führe. Die Autoren beziehen sich in ihrer

Arbeit auf ein zellenbasiertes Fertigungssystem. Dieses erlaube eine hohe Vielfalt und Individualisierung der hergestellten Produkte, benötige aber auch einen freien Fluss der Materialien und einen flexiblen Verkehr zwischen den einzelnen Zellen. Dadurch werde ein regelbasiertes Multiagentensystem, welches mit Hilfe von statischen Heuristiken arbeitet, den Ansprüchen eines solchen Systems nicht gerecht und könne die gegebenen Freiheitsgrade des Systems nicht vollends ausnutzen, weshalb nur ein Machine Learning basierter Ansatz in Frage komme. Für das Training des neuronalen Netzwerks nutzen die Autoren ein Simulationsmodell, welches auf der Discrete Event Simulation Logik basiert. Dieses Simulationsmodell bewertet vorgeschlagene Production Control Strategien und generiert somit Trainingsdaten für das Modell. Eine Metrik zur Erfassung der Systemleistung ist hierbei die Durchlaufzeit. Da diese erst mit Beendigung des Prozesses bestimmt werden kann, nutzen die Autoren Q-Learning, welche eine Methode des Temporal Difference Learnings ist. Diese Methode ist dazu geeignet, eine Schätzung des Endwerts für die Bewertung der Simulation abzugeben, um so die zeitliche Diskrepanz zu umgehen. Die Validierung des Modells findet in einer Simulation statt, mit der die Autoren ein zellenbasiertes Matrix-Produktionssystem mit zehn verbundenen Zellen repräsentieren. Dabei wird die Planungsaufgabe auf ein Markov Decision Problem heruntergebrochen, welches zur Darstellung einer dynamischen Umgebung eine sinusförmige Nachfragefunktion nutzt. Die Durchführung des Experiments erbringt bei der Nutzung des Machine Learning basierten Modells eine Verbesserung der Durchlaufzeit von 4.4% gegenüber dem regelbasierten Ansatz sowie eine Reduktion der blockierten Zustände im System von 8.4% auf 0.6%. Die Autoren können somit die von ihnen aufgestellten Thesen in einer Simulation validieren.

Greis et al. (2022) entwickeln in ihrer Arbeit ein Modell weiter, welches sie in einer vorangegangenen Publikation erarbeitet haben. Dieses beinhaltet ein Rahmenkonzept für einen Machine Learning basierten Digital Twin, welcher in der Lage sein soll, unerwartete Störungen in der Umwelt des Unternehmens zu kompensieren. Die Weiterentwicklung dieses Modells soll darin liegen, Augmented Reality mit kognitiven Fähigkeiten des Digital Twin zu verbinden. Das Ziel der Autoren ist es, ein Produktionssystem resilient gegenüber störenden Umwelteinflüssen zu gestalten. Hierbei geht es vor allem um Störungen, welche den Erfahrungsschatz des Machine Learning basierten Modells um einiges überschreiten. Als Basis eines guten Entscheidungsprozesses müsse dazu eine akkurate Repräsentation, der sich im physischen System befindlichen Parameter im Digital Twin gewährleistet sein. Die im Digital Twin enthaltenen Daten können in aufbereiteter Form in der Mensch-Maschine Schnittstelle bereitgestellt werden. Dafür soll ein Dashboard, welches mit Hilfe von Augmented Reality gewonnene Erkenntnisse interaktiv und visuell darstellt, fungieren. Für diesen Zweck kommen laut den Autoren Geräte, wie Smart Glasses oder Tablets und andere tragbare Geräte in Frage. Die Verwendung von Augmented Reality soll die Sicht des Entscheidungsträgers auf den Prozess mit Metadaten speisen und so für einen besseren Überblick sorgen sowie die Entscheidungsfindung des Algorithmus näherbringen. Im Zuge leaner und flexibler Prozessgestaltung wächst die Notwendigkeit von agilen KI-Lösungen zur kurzfristigen Anpassung von komplexer Produktionszeitplänen. In diesem Blickwinkel heben Greis et al. (2022) den Menschen als besonders wichtig für die Gestaltung eines robusten Steuerungssystems hervor, da er falsche oder unpassende Vorschläge des Machine Learning Modells anpassen und bewerten müsse. Während die Verwendung einer weniger komplexen Form dieser Technologie zur Informationsintegration schon in einer Siemens Fabrik in Auftrag gegeben sein soll, stecke das Konzept des Cognitive Digital Twin noch in

seinen Anfängen. Dieser soll laut den Autoren in der Lage sein, Entscheidungen mit minimaler menschlicher Interaktion zu treffen und ein Bewusstsein über Kontext, Ziele und Zeit mit sich bringen. Besonders in der Übergangsphase zu ausgereifteren Entscheidungsmodellen soll die Integration des Menschen in den Entscheidungsprozess, wie sie hier durch die Anwendung von Augmented Reality erreicht wird, zur Minimierung von Risiken und Steigerung der Güte des Modells beitragen.

Liu et al. (2023) stellen ein selbstorganisiertes Multi Agenten System zur Planung von Produktionszeitplänen auf Basis von Deep Reinforcement Learning vor, welches über klassische Faktoren hinaus die Verfügbarkeit und Ermüdung von Arbeitern in den Entscheidungsprozess miteinbezieht. Dabei entwickeln sie ein integriertes Deep Reinforcement Learning – Multi Agent System, welches die Entscheidung in drei Bereiche eingeteilt, bearbeitet. Für die Sequenzierung von Jobs und die Maschinenauswahl verwenden sie eine Reward Shaping Technik, welche positive Lang- und Kurzzeit Effekte vereinen soll. Währenddessen wenden sie für die Zuweisung von Arbeitskräften ein Attentionbased Network an. Die Anwendung dieses Systems gilt einem Re-Entrant Hybrid Flow Shop Scheduling Problem und soll mit einer Simulation validiert werden. Das vorgestellte Multi Agenten System verfolgt zwei Strategien, einerseits eine Verhandlungsstrategie, mit welcher der Produktionsprozess gesteuert wird und andererseits einer Disturbance Response Strategie. Die Disturbance Response Strategie soll in der Lage sein, die Folgen von unerwarteten Störungen abzumildern und betrachtet hierbei die Verfügbarkeit von Arbeitskräften und den Ausfall von Maschinen. In dem von den Autoren vorgestellten Modell ist das Multi Agenten System aus fünf Typen von Agenten aufgebaut. Dabei repräsentieren drei davon die Instanzen im Produktionsprozess, wie zum Beispiel Maschinen. Die verbleibenden zwei werden als planende Agenten genutzt, die Ressourcen im Produktionsprozess dem Zeitplan zuweisen. Dabei handelt es sich um den Stage Scheduling Agenten und den Worker Scheduling Agent. Die von ihnen zu lösende Scheduling Aufgabe besteht aus einer Sequenzierung von Entscheidungsprozessen und kann somit durch ein Markov Decision Problem modelliert werden. Für das Training der Agenten nutzen die Autoren den Reinforcement Learning Algorithmus Proximal Policy Optimization. Nach einer Evaluation möglicher Trainingsmethoden wenden sie das Deep Reinforcement Learning basierte Modell auf eine Fallstudie aus der Pharmaindustrie an. Hierbei können die Autoren feststellen, dass das System mehrere Störungen gleichzeitig abwenden kann sowie in der Lage ist, eine Verbesserung der Systemleistung gegenüber einem regelbasierten Dispatching System und einem weiteren Deep Reinforcement Learning Modell zu erzielen.

In ihrer Arbeit implementieren Stricker et al. (2018) einen Reinforcement Learning basierten Dispatching Ansatz, welchen sie in einem simulativen Fallbeispiel aus der Halbleiterindustrie mit klassischen Heuristiken vergleichen. Dafür erfährt der Reinforcement Learning Algorithmus ein simulationsbasiertes Offlinetraining, bis er das gewünschte Verhalten zur Steuerung von Dispatching Aufgaben in einer Job Shop Umgebung aufweist. Hierfür wenden die Autoren einen Q-Learning Ansatz an, welcher in der Lage ist, die zeitliche Diskrepanz von Aktionen und Rückmeldung des Systems abzubilden. Dadurch ist der applizierte Algorithmus über das initiale Offlinetraining hinaus in der Lage, sich im Produktionssystem an die Veränderung von Systemparametern anzupassen. Die Anwendung in ihrem Experiment zeigt eine

bessere Leistung des Reinforcement Learning basierten Ansatzes gegenüber dem Einsatz von klassischen Heuristiken zur Steuerung der Dispatching Aufgabe. Währenddessen erbringt die Heuristik jedoch eine stabilere Leistung mit kaum Abweichungen nach oben oder unten. Während dies auf den ersten Blick als ein Vorteil erscheint, wird bei näherer Betrachtung der Begründung dieser Tatsache deutlich, dass sie in Zusammenhang mit der Anpassungsfähigkeit des Reinforcement Learning basierten Modells steht. Der Algorithmus benötigt hierbei eine gewisse Zeit, das Entscheidungsmodell an die veränderten Bedingungen anzupassen und weist dadurch starke Abweichungen auf.

Kuhnle et al. (2019a) stellen die erfolgreiche Implementierung von einem autonomen Dispatching System in einem Fall aus der Halbleiter Industrie vor. Für ihr Modell nutzen die Autoren einen Single Agent Ansatz, welcher seine Autonomie durch Training auf Basis eines Trust Region Policy Optimization Algorithmus erlangt. Zur Validierung wird das entwickelte Modell in einem Fallbeispiel aus der Halbleiterindustrie angewendet. Dabei repräsentiert eine Simulation, welche zum Vergleich des Reinforcement Learning basierten Modells mit Heuristiken verwendet wird, die gegebenen Parameter aus dem realen Anwendungsfall. Somit können die Autoren beweisen, dass der Reinforcement Learning basierte Agent sowohl eine höhere Auslastung der Maschinen im System als auch geringere Durchlaufzeiten als die klassische Heuristik erreicht. Eine weitere Erkenntnis ist, dass die Größe der Pufferkapazitäten im Produktionsprozess ausschlaggebend für die Überlegenheit des Reinforcement Learning basierten Agenten ist. Diese befinden sich vor und nach den Maschinen und dienen als Zwischenspeicher von Produkten, bevor diese zu ihrer nächsten Station im Produktionsprozess transportiert werden. Bei größeren Puffern hat der Reinforcement Learning basierte Agent einen größeren Leistungsvorsprung aufgrund der höheren Fülle an treffbaren Entscheidungsmöglichkeiten. Zwar zeigt das Paper eine Integration des Agenten mit realen Falldaten, doch eine Verifikation in einem Produktionsprozess steht noch aus.

Kuhnle et al. (2019b) stellen einen Ansatz für das Design, die Implementierung und Evaluation von Reinforcement Learning Modellen vor. Diese dienen zur Anwendung bei Dispatching Aufgaben, welche in Job Shop Umgebungen angewendet werden sollen. Dazu gehört ein methodischer Ansatz zur Verwendung von Reinforcement Learning Algorithmen, wie Trust Region Policy Optimization, Proximal Policy Optimization oder Deep Q-Learning. Das Design wird hierbei in Action Space und State Representation sowie Reward Function und Hyperparameter aufgeteilt. Für alle Abschnitte stellen die Autoren eine auf Hauptfragestellungen heruntergebrochene Designmethodik für die Anwendung in Bezug auf Production Control Probleme auf. Die Methodik wird zum Abschluss exemplarisch angewendet, wobei das theoretische Modell und der genutzte Fall eine Weiterführung der Arbeit von Stricker et al. (2018) sind. Die Ergebnisse verdeutlichen die überlegene Maschinenauslastung und Leadtime des Reinforcement Learning basierten Modells gegenüber Heuristiken bei Dispatching Aufgaben in der Halbleiterindustrie und validieren die Anwendbarkeit des von den Autoren vorgestellten, Rahmenkonzepts für das Design, die Implementierung und Evaluation von Reinforcement Learning basierten Modellen in der Produktionssteuerung.

Zusammenfassend lässt sich sagen, dass Stricker et al. (2018), Kuhnle et al. (2019a) und Kuhnle et al. (2019b) eine aufeinander aufbauende Reihe an Arbeiten zur Integration von Reinforcement Learning in Order Dispatching für Job Shops darlegen. Diese baut von einer Integration in einem beispielhaften Fall, über den Einsatz in einer Simulation mit realen Falldaten auf, um schlussendlich einen Leitfaden für Design, Implementierung und Evaluation zu ihrem Modell einzuführen. Ähnlich zu dem vorangegangenen Unterkapitel nehmen auch hier nur eine Gruppe von Autoren bei der Entwicklung ihres Modells Bezug zur Resilienz des Produktionssystems (Greis et al. 2022). Während (Hofmann et al. 2020) die Leistung einer Deep Q-Learning basierten Produktionssteuerung mit einer auf Heuristiken basierenden Produktionssteuerung vergleichen, wählen Liu et al. (2023) und Greis et al. (2022) Ansätze, welche vor allem die Bedeutung des Menschen innerhalb des autonomen Produktionsprozesses in den Fokus rücken sollen.

4.3 Systembetrachtung

Dieses Unterkapitel setzt sich mit Literatur auseinander, welche weniger eine konkrete Anwendung, wie die Optimierung von Wartungs- oder Produktionszeitplänen verfolgen, sondern vielmehr eine Systembetrachtung durchführen. Hierbei werden Architekturen und Betrachtungsweisen von Produktionskontrollsystmen aufgestellt und von den Autoren verglichen. Sie richten einen holistischen Blick auf Produktionssysteme und deren resiliente Gestaltung sowie zukunftsträchtige Technologien zur Verbesserung von autonomen Produktionssteuerungen.

Antons und Arlinghaus (2021) vergleichen in ihrer Arbeit Centralized und Distributed Production Control Ansätze für Smartfactories. Hierbei betrachten die Autoren die Entscheidungen, welche in dem jeweiligen Production Control System über die Zuweisung von Jobs an Maschinen und deren Sequenzierung getroffen werden. Darüber hinaus integrieren sie über die Einführung von Maximum Likelihood Estimators in den Multi Agenten Ansatz die Fähigkeit des Systems, sich über seine Betriebsdauer selbst anzupassen. Hierbei nutzen die Autoren die Integration von Informationen aus dem CPS, welche durch Sensoren im Prozess gewonnen werden. Die Maximum Likelihood Estimators werden auf Basis historischer Daten von jedem Maschinen Agenten lokal erzeugt. Diese Integration wird sowohl für den Centralized, als auch den Distributed Production Control Ansatz vollzogen. Dies geschieht im Falle der Distributed Production Control auf Basis einer Queue Length Estimation, welche dazu genutzt wird, Jobs auf Maschinen zu verteilen. Im Falle des Centralized Production Control Ansatzes wird ein Mixed Integer Linear Program für die Zuweisung von Jobs verwendet. Dadurch wird ein globaler Produktionsplan erstellt, bei dem die jeweiligen lokalen Agenten als reine Empfänger fungieren. Die Anwendung des Maximum Likelihood Estimators führt in beiden Fällen zur Schaffung eines lernfähigen Modells. Zusätzlich wird im Allgemeinen eine FIFO-Regel zur Sequenzierung der jeweiligen Jobs verwendet. Die vorgestellten Produktionskontrollsystme werden daraufhin mit und ohne die Nutzung des Maximum Likelihood Estimators, also in vier sich ergebenden Szenarien, in einer Simulation verglichen. In dieser zeigen die Autoren, dass die Integration einer Lernkomponente durch den Maximum Likelihood Estimator zu einer Steigerung der Systemleistung führt. Zusätzlich wird deutlich, dass der Centralized Production Control

Ansatz eine im Schnitt bessere Leistung als die Decentralized Production Control erreicht, jedoch eine höhere Streuung der Ergebnisse und eine deutlich längere Rechenzeit durch die Komplexität des von einer zentralen Steuerungseinheit zu bewältigenden Verfahrens benötigt.

Sheth und Kusiak (2022) diskutieren in ihrer Arbeit die aktuelle Sicht auf Resilienz, welche meist aus einer technischen, beziehungsweise Stabilitätsperspektive betrachtet wird. Statt dieser Sichtweise schlagen die Autoren eine Betrachtung von Resilienz vor, welche die Fähigkeiten des Systems, Risiken zu verstehen und sich an Veränderungen anzupassen in den Fokus rückt. Für die Betrachtung der Risiken teilen sie diese in die fünf Kategorien externes sowie internes Umfeld, Prozesse im Produktionssystem, technologischer Fortschritt und das Angebots- und Nachfragernetzwerk, inklusive der Rolle des Menschen. Durch die Ergebnisse ihrer Literaturrecherche sind die Autoren sich sicher, dass das sogenannte Industrial Information Integration Engineering, was durch Kerntechnologien, wie dem Digital Twin und Machine Learning ermöglicht wird, ein zentraler Baustein in der Gestaltung resilenter, produzierender Unternehmen sein werde. Dabei könne man sich die Erfassung der Datenströme durch eine Integration in die Planung und Steuerung des Prozesses zu Nutze machen. Jedoch könne schon allein die Sichtbarkeit von Echtzeitdaten aus der Produktion und seiner Umwelt das System resilenter machen. Dabei könnten Risiken, welche von dem Zustand der Lieferkette sowie der Maschinen im Produktionssystem ausgehen, minimiert werden. Hierbei heben die Autoren besonders die Funktionen der Logistik, was unter anderem die Lagerhaltung und den Transport der hergestellten Produkte betrifft, als einen entscheidenden Faktor in der Gestaltung eines resilienten Unternehmens hervor. Zuletzt führen sie an, dass Produktionssysteme in Zukunft als Complex Adaptive Systems betrachtet werden müssen. Diese sollen in der Lage sein, sich selbst proaktiv in einer fast evolutionären Art und Weise anzupassen, statt nur auf Umweltzustände zu reagieren.

Qin und Lu (2021) stellen in ihrer Arbeit eine Architektur vor, welche die Sicht von produzierenden Unternehmen als Self Organizing Manufacturing Systems aufgreift und diese weiterführt. Durch die weltweite Vernetzung der Produktionssysteme sei die Ansicht von einzelnen Strukturen nicht mehr hinreichend und soll sich zu einer Sicht auf Self Organizing Manufacturing Networks weiterentwickeln. Die Einführung des Netzwerkcharakters soll hierbei über die globale Vernetzung der autonomen Komponenten in den Produktionsprozessen stattfinden. Ein Centralized Production Control Ansatz sei hierbei dazu geeignet, netzwerkoptimale Entscheidungen zu treffen. Dieser erlangt laut den Autoren jedoch die Flexibilität und die Fähigkeit der Kommunikation im Produktionsnetzwerk, welche ein Decentralized Production Control Ansatz mit sich bringt. Daher schlagen sie die Benutzung von Partially Decentralized Architekturen vor, welche die Fähigkeiten beider Produktionssysteme ineinander vereinen. Darüber hinaus definieren die Autoren Self Configuration, Self Optimization und Self Healing als Kerneigenschaften eines Self Organizing Manufacturing Networks. Für die Erfüllung dieser Eigenschaften werden im Kern Multi Agenten Systeme und Reinforcement Learning Algorithmen als notwendige Technologie erachtet, welche die Adaptierbarkeit und Lernfähigkeit des Systems gewährleisten. Des Weiteren heben die Autoren die Signifikanz von standardisierten Soft- und Hardware Lösungen hervor, welche erst die Self Configuration des Netzwerks ermöglichen. Damit ist die Einführung eines Paradigmas,

welches sie Plug-and-Produce bezeichnen, möglich. Dieses soll die nahtlose Verknüpfung und Anpassung von Produktionssystemen mithilfe von Machine Learning basierten Algorithmen auf globaler Ebene erlauben.

Peukert et al. (2023) untersuchen, wie Robustheit in produzierenden Betrieben auf globaler Ebene erreicht werden kann. Dafür soll die Sicht auf Robustheit von der Betrachtung einzelner Komponenten des Produktionssystems hin zu einer Perspektive auf die Gesamtheit des Netzwerks abgewendet werden. Hierbei soll speziell eine Integration der Betrachtung von Produktionsprozessen und der Logistik des Unternehmens stattfinden, um für die verteilten Produktionssysteme netzwerkoptimale Entscheidungen zu treffen. Im Rahmen ihrer Forschung wollen die Autoren dafür einerseits feststellen, welche Kombinationen aus Gegenmaßnahmen für Störungen in der Umwelt des Unternehmens dazu geeignet sind, die Robustheit eines globalen Produktionssystems zu steigern. Andererseits machen sie es sich zum Ziel, die Vorteile von automatisierten, computergestützten Entscheidungsprozessen gegenüber klassischen Entscheidungsfindungen, welche meist auf Basis von Erfahrung und Intuition durch die Operatoren des Systems getroffen werden, zu identifizieren. Darüber hinaus ist den Autoren die Entwicklung eines Rahmenkonzepts, welches nicht abhängig von einem Spezialfall, sondern universell anwendbar ist, ein Anliegen. Dazu stellen sie ein Konzept vor, welches basierend auf Simulationen die Analyse der Robustheit eines Netzwerks erlauben soll. Hierzu wird das Vorgehen in drei Phasen unterteilt. Die Modellierung beinhaltet die holistische Betrachtung des Systems und die Klassifizierung von möglichen Störungen und Gegenmaßnahmen. Die Analysephase betrachtet auf Basis von auf dem zuvor modellierten Netzwerk abgehaltenen Simulationen Ursachen der klassifizierten Störungen und identifiziert mögliche Kombinationen von Maßnahmen gegen besagte Störungen. Schlussendlich folgt die Empfehlung, in der unter Betrachtung der Robustheit die möglichen Gegenmaßnahmen bewertet werden. Für die Validierung dieses Rahmenkonzepts wenden die Autoren das Vorgehen auf eine Fallstudie, basierend auf der Produktionslinie eines Flugzeugherstellers, an.

In ihrer Arbeit über resiliente Kreislaufwirtschaften untersuchen Paraschos et al. (2022) (Re-) Manufacturing Systeme mit stochastisch degradierenden Eigenschaften. Dazu stellen sie ein Rahmenkonzept auf, welches sowohl den Betrieb als auch den Entwurf von Produktionssystemen mit Kreislaufwirtschaften betrachtet. Hierfür dient ein Ansatz für die Produktionssteuerung, welcher Reinforcement Learning und ad-hoc Produktionsregeln vereint. Dabei wird ein Agent mit Hilfe von Reinforcement Learning trainiert, kann währenddessen aber auch auf klassische ad-hoc Produktionsregeln zugreifen, welche die Leistung des Agenten erhöhen sollen. Zu diesen Regeln zählen im Ansatz der Autoren unter anderem Kanban sowie Extended Kanban, CONWIP, Base Stock und (s,S). Diese sollen die Leistung des Agenten in Bezug auf die Autorisierung von Produktions- oder Wartungsmaßnahmen sowie dem Einsatz von Recycling und Remanufacturing Maßnahmen im Produktionsprozess steigern. Die Validierung ihres Rahmenkonzepts halten die Autoren in einer Simulation ab, in der Versuche basierend auf Markov Decision Problems stattfinden. Dabei werden Variationen des Modells mit verschiedenen Kombinationen von integrierten ad-hoc Regeln untereinander und mit einem reinen Reinforcement Learning basierten Agenten verglichen. Dabei können die Autoren

feststellen, dass die Integration von ad-hoc Regeln in den Entscheidungsprozess des Agenten eine signifikante Steigerung seiner Leistung zur Folge hat. Der integrierte Ansatz sichert dabei laut den Autoren immer einen adäquaten Bestand an Produkten im Angesicht von schwankender Nachfrage zu und steigert die Kosteneffizienz durch erhöhte Recyclingaktivitäten. Zudem wird durch die Einbeziehung der Systemgesundheit, in Anbetracht von degradierenden Komponenten an Maschinen stets eine hohe Güte der Produkte gewährleistet. Somit beobachten die Autoren, durch die Integration von ad-hoc Regeln in die Machine Learning basierten Agenten, eine Steigerung der Resilienz des Systems.

In ihrer Forschung zu resilienten Produktionssystemen stellen Mukherjee et al. (2022) einen Ansatz vor, welcher durch die Applikation von Methoden, die zum Training künstlicher Intelligenzen eingesetzt werden, zurückgreift. Dabei handelt es sich um Adversial Attacks, welche die Autoren einsetzen, um die Produktionssteuerung resilenter zu gestalten. Resilienz definieren die Autoren in diesem Kontext als die Fähigkeit sich gegen durch Störungen in der Umwelt des Systems verursachte Veränderungen zu widersetzen sowie einer Kombination der Begriffe Robustheit und Agilität. Bei Adversial Attacks unterscheiden die Autoren zwischen Whitebox und Blackbox Attacks, welche sich durch das Wissen über den Aufbau des angegriffenen Systems unterscheiden. Hierbei wird eine Whitebox verwendet, welche über alle Parameter des angreifenden Systems Bescheid weiß. Bei dem System, welches im Vorgehen der Autoren angegriffen wird, handelt es sich um die Umgebung einer Simulation. Diese Simulation wird genutzt, um Datensätze zu generieren, welche schlussendlich für das Training eines resilienten Machine Learning Modells zur Produktionssteuerung eingesetzt werden sollen. Dabei simulieren die Attacken Störungen des Umfelds, welche durch reale Gegebenheiten, wie Kriege, Pandemien oder Umweltkatastrophen inspiriert werden. Dadurch ergeben sich aus der Simulation Datensätze, welche diese Gegebenheiten widerspiegeln. Neben dieser Technik kann auch das sogenannte Adversial Training zum Einsatz kommen, bei dem einzelne Parameter des Systems gestört werden. Dadurch lassen sich mögliche Schwachstellen des Systems identifizieren, was zur Modellierung resilenter Produktionssysteme beitragen soll. Ihre Vorgehen validieren die Autoren an einem beispielhaften Fall, welcher das Vorgehen auf eine Fertigung von Bürostühlen anwendet.

Leng et al. (2023) vereinen in ihrer Arbeit vorteilhafte Elemente aus autonomen und dezentralisierten Produktionssystemen, indem sie Blockchain basierte Technologien in Produktionsnetzwerke integrieren, um resiliente Systeme für die Zukunft zu entwickeln. Diesen Ansatz bezeichnen die Autoren hierbei als Decentralized Autonomous Manufacturing. Laut den Autoren sollen Dezentralisierung und Autonomie zentrale Eigenschaften für die Gestaltung resilenter Produktionssysteme darstellen. Die von ihnen vorgestellte Architektur beruht auf Blockchain 3.0 und 2.0 Technologien, wobei Blockchain 3.0 als Decentralized Application und Blockchain 2.0 als Smart Contracts definiert werden. Smart Contracts bieten hierbei die Möglichkeit der Peer-to-Peer Kommunikation zwischen Maschinen in der Produktionsanlage, dabei können Aufträge autonom und selbstständig über Bidding- oder Verhandlungsmodelle zwischen den produzierenden Maschinen verteilt werden. Darüber hinaus bieten Decentralized Applications die Basis für die Netzwerkarchitektur, welche die dem vorgestellten Ansatz zu Grunde liegenden Decentralized Autonomous Organizations nutzen. Die Autoren heben sowohl die

Wichtigkeit einer offenen und modulierten Architektur des Decentralized Autonomous Manufacturing als auch die Möglichkeit der Kombination von Blockchain und anderen Technologien, wie Multi Agenten Systemen oder KI hervor.

Hosseini et al. (2016) stellen ein Rahmenkonzept vor, mit dem es möglich ist, die Resilienz von Systemen zu bewerten. Obwohl die Autoren das Konzept für die Betrachtung von Lieferketten erstellen, lasse es sich ebenso auf die Betrachtung und Erstellung anderer resilenter Infrastruktursysteme wie zum Beispiel Produktionssysteme anwenden. Dazu teilen sie das Vorgehen in die fünf Phasen Threat Analysis, Resilience Capacity Design, Resilience Cost Evaluation, Resilience Quantification und Resilience Improvement ein. Des Weiteren definieren die Autoren die Resilienz eines Systems als eine aus mehreren Bestandteilen aufgebaute Kapazität. Diese werden in die absorptive, adaptive und wiederherstellende Komponente des Systems aufgeteilt. Dieses Vorgehen wenden die Autoren auf ein Fallbeispiel aus der Schwefelsäureproduktion an. Hierzu müssen in einem ersten Schritt die Resilienzkapazität sowie Risiken und Risikobewältigungsstrategien durch Expertenwissen ermittelt werden, welche im Folgenden durch Bayessche Netzwerke ausgewertet werden. Die genutzte Metrik ist hierbei das Verhältnis aus der nach einer Störung des Systems wiederhergestellten Produktion und der möglichen verlorenen Produktion. Dieses Konzept kann auch zur Sensibilitätsanalyse, also der Erfassung der Auswirkung einzelner Parameter, auf die Resilienz eingesetzt werden. Des Weiteren lässt sich durch den Einsatz von Bayesschen Netzwerken Belief Propagation betreiben, dadurch lassen sich Aussagen über das Verhalten des Systems verteilt auf seine Komponenten beim Eintreten bestimmter Szenarien treffen.

Ehrhardt und Hoffmann (2020) stellen einen Ansatz vor, um die Informationen aus einem Digital Shadow zur Optimierung von Produktionssystemen zu nutzen. Sie greifen hierbei bewusst auf den Digital Shadow, welcher einen Teil des Digital Twin darstellt, zurück. Laut den Autoren reiche für die reine Präsentation von Daten der Digital Shadow aus und vermeidet den zusätzlichen Aufwand, welchen die Modellierung eines Digital Twins verursachen würde. Hierbei ist eine volle Integration des Produktionsprozesses in das Cyber Physical Production System nötig, sodass ein brauchbarer Digital Shadow entstehen und zur Nutzung von entstehenden Strömen von Echtzeitdaten genutzt werden kann. Das von ihnen vorgestellte Modell nutzt einen Genetic Algorithm, um die Daten aus dem Digital Shadow zu verarbeiten und soll zum Einsatz in vielfältigen Flow Shop Aufgaben geeignet sein. Zur Validierung ihres Modells implementieren die Autoren den Digital Shadow und den Genetic Algorithm in ein Programm, welches mit Daten aus einer simulierten Produktionsumgebung gespeist wird. Für den simulierten Produktionsprozess erstellt der Algorithmus in einem Testverfahren Produktionspläne, welche eine Verbesserung gegenüber den Referenzplänen aufweisen. Zusätzlich kommt das Modell in einem realen Fallbeispiel eines Fräsbetriebs zum Einsatz. Auch hier konnten die Autoren eine Optimierung des Produktionsplans und somit eine erfolgreiche Implementierung des Digital Shadow in dem Entscheidungsprozess erreichen.

In ihrer Arbeit stellen Di Orio et al. (2015) auf dem Weg zu Self-Learning Production Systems eine Komponente vor, welche für die Adaption des Produktionssystems an veränderte Umstände in seiner

Umgebung zuständig ist. Diese Komponente bezeichnen die Autoren als Self-Learning Adapter (kurz Adapter). Dem Adapter ist der sogenannte Extractor vorgeschaltet, welcher für die Integration von Datenströmen aus der Produktionsumgebung zuständig ist und diese in einem Data Access Layer speichert. Der Adapter selbst ist für die Anpassung der Parameter im Prozess zuständig und gibt diese als Vorschlag in einem Benutzerinterface an einen Menschen im Produktionsprozess aus. Dieser bewertet den entstandenen Vorschlag und wendet die enthaltenen Änderungen gegebenenfalls auf den Prozess an. Die von dem Experten getroffene Entscheidung wird als Bewertung an ein Lernmodul weitergeleitet, welches über einen Reinforcement Learning Algorithmus das dem Entscheidungsprozess zugrundeliegende Modell dementsprechend anpasst. Die Motivation für die Entwicklung des Modells haben die Autoren auf Basis von drei Industriefallstudien gezogen. Dabei entstand das Ziel, die Architektur für ein möglichst breit anwendbares und einfach zu adaptierendes Modell zu entwickeln. Dabei war der Fokus, das Modell in flexiblen Produktionsumgebungen für Scheduling und Dispatching Aufgaben einzusetzen. Die Validierung der vorgestellten Architektur nehmen die Autoren in einer Simulation vor, welche an einen der angeführten Industriefälle angelehnt ist.

Brettel et al. (2016) beschäftigen sich in ihrer Arbeit mit den Bedingungen, welche zur Ermöglichung von selbstoptimierenden Produktionssystemen erfüllt werden müssen. Den Prozess der Selbstoptimierung gliedern sie hierbei in die Erfassung des Systemzustands, das Festlegen der Ziele und die Anpassung des Systemzustands ein. Zur Ermöglichung solcher Systeme haben die Autoren vier Bedingungen aufgeführt: Cognition, die Fähigkeit Informationen zu verarbeiten und Autonomy, die Befähigung, dass Aktionen ohne einen externen Eingriff ausgeführt werden können, machen es dem System möglich, seine gegebenen Freiheitsgrade auszuschöpfen. Die Freiheitsgrade definieren sich laut den Autoren aus Flexibility, was die Möglichkeit der Adaption an sich ändernde Bedingungen beschreibt und Variability, was die Fähigkeit eines Systems beschreibt, seine internen Strukturen anzupassen. Die Autoren applizieren zur Validierung ihres Ansatzes das vorgestellte selbstoptimierende Produktionssystem in zwei beispielhaften Fällen. Hierbei wird es in einer mit Lasern arbeitende Produktionsumgebung integriert, in der ein Multi Agenten System für die autonome Entscheidungsfindung genutzt wird. Der reale Anwendungsfall zeigt eine Minimierung des Planungsaufwands, eine erhöhte Flexibilität im Produktionsprozess und beweist eine Lernfähigkeit des Systems. In einem zweiten Fall wird der Ansatz auf ein Self Organizing Material Flow for Plug & Produce-able Modular Assembly System angewendet. Hierbei kann die verwendete Kontrollstruktur die Flexibilität und Variabilität des komplexen Materialtransportsystems erhöhen, wobei das System laut den Autoren noch ausbaufähige Fähigkeiten in den Bereichen Cognition und Autonomy besitzt und der Ansatz in diesem Anwendungsfall somit nur teilweise validiert werden kann.

In ihrer Arbeit präsentieren Arzi und Herbon (2000) einen Ansatz zur Integration eines Distributed Production Control Systems zur Anwendung in einer zellenbasierten Fertigung. Hierbei verfügen alle Fertigungszellen über eine autonome und adaptive Steuerungseinheit, welche lokale, kurzzeitig verfügbare Informationen periodisch überwacht und die Systemparameter an die entsprechenden Gegebenheiten anpasst. Dafür nutzen die Autoren einen probabilistischen Machine Learning Algorithmus, welcher dafür sorgt, dass das System nicht an seine Startparameter gebunden ist und sich selbst an

zufallsbasierte Störungen anpasst. Dieses Modell validieren die Autoren in einer Simulationsreihe gegenüber einem Distributed Production Control System ohne adaptive Steuerung und eine signifikante Verbesserung in der Durchsatzleistung sowie eine Verringerung der Verspätungen auf Grund von Maschinenausfällen feststellen.

Möhring et al. (2020) stellen in einer Literaturrecherche zu Self-Optimizing Machining Systems Schlüsseltechnologien und Strategien zur Selbstoptimierung vor. Dabei beziehen sich die Autoren speziell auf die Anwendung bei Fräsmaschinen. Als technische Grundlagen nennen die Autoren vor allem die Integration von robusten Sensoren sowie die Verarbeitung und Überwachung der erlangten Daten. Dabei müsse unter anderem eine Verbindung der Sensoren mit den Aktoren und Steuerungen der Fräsmaschinen stattfinden. Somit könnten die Maschinen in der Lage sein auf thermische Einflüsse, wie zu hohe Werkzeugtemperaturen oder mechanische Störungen, wie Vibrationen reagieren, um diese zu kompensieren. Außerdem sei künstliche Intelligenz und Simulationen eine hohe Rolle in der Entwicklung von Self-Optimizing Machining Systems zuzuschreiben. Hierbei könnte die Kombination der Vorhersage von Bearbeitungsergebnissen und -zeiten genutzt werden, um diese in eine Effiziente Produktionsplanung einbauen. Des Weiteren lassen sich Vorhersagen über die Lebensdauer von Werkzeugen treffen, was die Effizienz und Sicherheit des Betriebs erhöhen könnte. Die Nutzung von Machine Learning basierten Algorithmen erlaubt es außerdem, dass sich die Systeme immer weiter verbessern, während eine Kommunikation im System positive, maschinenübergreifende Lerneffekte zum Vorschein bringen könnten. Ein Kernaspekt der aktuellen Literatur ist laut den Autoren die Beschränkung auf einzelne Maschinen. Eine Integration ganzer Prozessketten könnte hingegen die Möglichkeit bieten, dass diese untereinander kommunizieren und voneinander lernen.

Klaas et al. (2013) stellen in ihrer Arbeit ein selbstadaptierendes Produktions-Kontrollsystem vor. Dieses nutzt im Gegensatz zu klassischen Ansätzen, die als Folge von Störungen oder Änderungen einen Anpassungsprozess beginnen, ein Vorhersagemodul, um so proaktiv auf Störungen reagieren zu können. Diese Komponente sagt basierend auf bekannten Mustern die Veränderung von Systemparametern voraus, die dann in einer Simulationsumgebung angepasst werden, um Trainingsdaten für das Machine Learning basierte Kontrollsystem zu generieren. Dadurch ist das nötige Wissen beim Eintreten der Veränderungen bereits vorhanden und das System kann adäquat reagieren. Die Autoren entwickeln eine Software zur Evaluation diverser Forecasting Methoden und wenden ihr Konzept auf ein Fallbeispiel in einer Lagerhalle an. Hierbei stellt sich für diesen Fall 2nd Exponential Smoothing als beste Vorhersagemethode heraus. Diese Methode war akkurat genug, um aus den vorhergesagten Parametern brauchbare Datensätze für das Modelltraining zu generieren.

Leng et al. (2022) führen Elemente der Blockchain Technologie in eine Multi Agenten basierte, autonome Produktionssteuerung ein. Die Produktionssteuerung wird hierbei in die obere und untere Schicht geteilt, deren Aufgaben das initiale Dispatching, beziehungsweise die autonome Steuerung im Zuge von Störungen ist. Den Schichten sind unterschiedliche Agenten zugewiesen, welche über das Blockchain

Netzwerk miteinander kommunizieren und kooperieren können. Dabei werden kritische Informationen im BC-Netzwerk gespeichert, was den Vorteil mit sich bringt, dass diese manipulationssicher sind und so die Authentizität und Zuverlässigkeit der Daten gesichert ist. In der Distributed Production Control werden die Aufgaben über eine Smart Contract Negotiation zwischen den Agenten verteilt und ausgeführt. Zur Validierung haben die Autoren ihr Modell in einer simulativen Fallstudie zu einem PCB-Hersteller und einem weiteren Experiment mit einem Contract Network Protocol angewendet und kommen zu dem Schluss, dass die Einführung von Blockchain Technologie das Production Control System resilenter und sicherer gestalten kann, wobei dabei eine vertretbare Verlangsamung der Berechnungsprozesse in Kauf genommen werden muss.

Byrne et al. (2021) diskutieren in ihrer Arbeit die Hypothese, ob zukünftige Produktionssysteme Komponenten enthalten werden, die eine Konvergenz der technischen Systeme hin zu lebenden Systemen erlauben. Dazu haben die Autoren vier Demonstratoren entwickelt, welche näher auf die Design Methodik von Produkten, Sensoren und Prozessen sowie die Produktionssysteme eingehen und dabei die Kategorien Bio-Inspiration, Bio-Intelligenz und Bio-Integration erkunden sollen. Die Konvergenz kommt laut den Autoren zum einen durch einen technischen Pull, also dem gezielten Suchen nach biologischen Mechanismen, welche sich auf das identifizierte, technische Problem anwenden lassen. Zum anderen könnte es zum biologischen Push kommen. Hierbei werden für entdeckte Phänomene und Eigenschaften aus der Biologie nach Anwendungsmöglichkeiten in technischen Lösungen gesucht. Aus der Vorstellung der untersuchten Demonstratoren ist besonders Demonstrator drei, welcher sich mit der Integration von Bio-Intelligenz in einen additiven Fertigungsprozess beschäftigt, hervorzuheben. Dafür werden diverse Artificial Intelligence Anwendungen getestet, um unter anderem mit einer Kamera die Fehlererkennung und den Entscheidungsprozess zu automatisieren. Die Autoren sprechen in diesem Fall von Bio-Intelligenz, da in das System somit die Fähigkeiten zu kommunizieren, von Anwendern zu lernen, aber auch unerfahrene Anwender lehrend zu unterstützen integriert werden. Die Anwendung an allen vier Demonstratoren zeigt den Autoren, dass die Konvergenz mit Biologie eine Leistungssteigerung der Systeme zur Folge haben könne.

5 Literatursynthese

In diesem Kapitel werden die Inhalte der recherchierten Literatur diskutiert und eingeordnet. Dazu werden der aktuelle Stand und Entwicklungen in der Forschung dargelegt sowie Lücken und mögliche Forschungsausrichtungen für die Zukunft identifiziert. Das Kapitel wird in mehrere Unterkapitel gegliedert und ist wie folgt aufgebaut:

In Abschnitt 5.1 wird der Aspekt Resilienz in der recherchierten Literatur diskutiert. Dabei werden in der Literatur abweichende Definitionen, Die Nutzung des Begriffes sowie die Messung und Bewertung von Resilienz diskutiert. Des Weiteren liefert 5.2 zuerst einen Überblick des aktuellen Stands der Technik bei der Eingliederung von Resilienz in den Produktionsprozess und die Ansätze seiner Autonomisierung. Dabei entsteht eine Synthese der zuvor dargelegten Ansätze in den Bereichen Maintenance sowie Scheduling & Dispatching. Darauf folgt eine weniger Praxisorientierte Betrachtung der Entwicklung von Systemarchitekturen und deren Betrachtungsweisen in Bezug auf resiliente und autonome Produktionssysteme. Schlussendlich soll 5.3 einen Überblick auf identifizierte Lücken in der Literatur zur resilienten Produktionssteuerung bieten sowie mögliche Forschungsrichtungen zur Weiterführung aktueller Konzepte bieten.

5.1 Betrachtung von Resilienz

Ein zentraler Aspekt dieser Arbeit ist die Betrachtung der Resilienz eines Produktionssystems. In diesem Kapitel wird analysiert, inwiefern die Autoren die Betrachtung von Resilienz oder ihren Komponenten bei der Entwicklung ihrer Modelle mit einbezogen haben. Hierbei wird sich auf die im Grundlagenkapitel 2 aufgestellte Resilienzdefinition im Kontext von Wertströmen (Steinmeyer und Metternich 2023) bezogen. Nach dieser Definition lassen sich als Kernkomponenten neben der Robustheit und Agilität eines Systems die Vorhersage von Störungen und die Fähigkeit zur Selbstanpassung an neue Rahmenbedingungen hervorheben, welche über die in der Literatur angeführten Definitionen von Resilienz oft hinausgehen. Dazu wird dieses Kapitel in drei Schritte geteilt. In einem ersten Schritt wird analysiert, inwiefern sich die Autoren auf Resilienz beziehungsweise ihre benannten Kernkomponenten beziehen. Daraufhin werden im zweiten Abschnitt die von den Autoren verwendeten Definitionen dargelegt. Der dritte Abschnitt beschäftigt sich mit der Quantifizierung und Bewertung von Resilienz sowie einer möglichen Normung des Begriffs.

5.1.1 Bezug auf Resilienz und ihre Komponenten

Durch eine Auswertung der in Kapitel 4 vorgestellten Literatur können Aussagen über die thematische Ausrichtung der Autoren getroffen werden, welche in einer übersichtlichen Auflistung in Kapitel 3 zu finden sind. Dieses kurze Unterkapitel bricht die in der Analyse gesammelten Erkenntnisse über die Verwendung und den Bezug zur Resilienz als Eigenschaft von Produktionssystemen sowie der Komponenten Robustheit, Agilität und Adaptivität herunter. Obwohl die gesamte vorgestellte Literatur Beiträge zur Gestaltung resilenter Produktionssysteme liefert, kann durch die Auswertung der Inhalte

festgestellt werden, dass nur zwölf der 26 Paper sich überhaupt mit dem Begriff auseinandersetzen. Stattdessen werden meist Robustheit, Agilität oder Adaptivität als Eigenschaften der entwickelten Modelle angeführt, welche in Kapitel 2 als Zielgrößen der Gestaltung resilenter Systeme identifiziert werden. Dabei wird durch die vorgestellten Modelle in 19 Fällen die Robustheit und Adaptivität sowie in 17 Fällen die Agilität der Systeme berührt. Dies geht aus der Volltextanalyse der Literatur hervor und gilt einem groben Überblick der Themen, mit denen sich die Autoren beschäftigen. Besonders auffällig ist außerdem, dass die thematische Gruppierung der Literatur in starkem Zusammenhang mit dem Bezug auf Resilienz steht. In den Gruppen Maintenance und Scheduling & Dispatching nehmen jeweils nur eine der vier, beziehungsweise sechs Arbeiten bei der Entwicklung ihrer Modelle Bezug auf die Resilienz des Systems. Währenddessen ergibt sich aus der Analyse der Gruppe Systembetrachtung, dass sich immerhin zehn der 16 Autoren auf diese Eigenschaft beziehen. Daraus lässt sich schließen, dass die Betrachtung von Resilienz auf Systemebene deutlich weiter fortgeschritten ist als bei der Applizierung von konkreten Modellen in den angeführten Bereichen.

5.1.2 Definitionen

In diesem Abschnitt werden Auszüge von Definitionen der Resilienz im Kontext der Produktionsumgebung präsentiert. Diese werden untereinander verglichen, um Unterschiede und Gemeinsamkeiten sowie die mit den Problemen der Begriffsfindung einhergehenden Schwierigkeiten für die akademische Entwicklung des Themas zu verdeutlichen. Dazu muss man erwähnen, dass die Entwicklung von resilienten Produktionssystemen noch in den Kinderschuhen steckt und wohl erst von Zhang und van Luttervelt (2011) in den Diskurs eingebbracht wird.

Von den zwölf Autoren, die sich in ihrer Arbeit auf die Resilienz von Systemen beziehen, führen sieben keine Definition der Resilienz an. Dabei nutzen einige Autoren, wie unter anderem von Byrne et al. (2021), Resilienz eher synonym zu Robustheit. Hosseini et al. (2016) analysieren in einer Literaturrecherche Ansätze zur Definition von Resilienz, die meist die Resistenz gegen Störungen sowie die Heilung von diesen und Adaption an die neuen Begebenheiten beinhalten. Damit begründet behandeln sie die Resilienz als Kapazität und teilen sie eine absorptive, adaptive und wiederherstellende Komponente ein. Diese Kategorisierung nutzen auch Leng et al. (2023). Des weiteren Definieren sie Resilienz folgendermassen: „resilience refers to the ability of a system to keep or recover quickly to a stable state during and after a major mishap under severe disruptions or in the presence of continuous significant stresses“ (Leng et al. 2023, S. 100). Hierbei treffen sie eine distinkte Unterscheidung zu der Robustheit eines Systems. Währenddessen bezeichnen Mukherjee et al. (2022) Resilienz als die Fähigkeit mit störungsinduzierten Änderungen in der Umgebung des Produktionssystems umgehen zu können und identifizieren die Kombination von Agilität und Robustheit als Kernqualitäten eines resilienten Systems. In der Arbeit von Paraschos et al. (2022) wird Resilienz als Fähigkeit nach mehreren Störungen die Funktionsfähigkeit des Produktionssystems wiederherzustellen und die Profitabilität zu wahren. Darüber hinaus schreiben sie einem resilienten System die Fähigkeit zu, aus Ausfällen und Störungen zu lernen. Dagegen wählen Sheth und Kusiak (2022) eine Definition der Resilienz, welche über die von ihnen beschriebene Engineering Resilience hinausgeht und eine Risikokomponente einführt. Dabei beschreibt Engineering Resilience die Fähigkeit eines Systems, nach einer Störung aus einem ungewollten in den gewollten Systemzustand zurückzugelangen. Hierbei führen sie „(1) The external/operating environment; (2) The

internal/enterprise environment; (3) Manufacturing processes; (4) Technological advancements; and (5) Demand-supply networks and people's role" (Sheth und Kusiak 2022, S. 5) als Risiken des Systems an, welche ein resilientes System abzuwenden und zu identifizieren hat. Dieser Ansatz ähnelt dem von Steinmeyer und Metternich (2023), bei dem Sie Resilienz über die Risiken, welchen ein Wertstrom ausgesetzt ist, definieren.

Aus diesem Vergleich geht hervor, dass die Definition von Resilienz im Produktionskontext ein breit gestreutes Spektrum von Ansetzen widerspiegelt. Dabei lässt sich aus den zuvor angeführten Definitionen herausziehen, dass die wohl konstanteste Eigenschaft, welche einem resilienten Produktionssystem zugeschrieben wird, der Umgang mit Störungen und Ausfällen ist. Darüber hinaus könnte die Definition der Resilienz als Kapazität und ihre Unterteilung in einzelne Komponenten (Leng et al. 2023; Hosseini et al. 2016) die Möglichkeit einer besseren Erfassung und Bewertung der Systemresilienz bieten.

5.1.3 Normung, Messung und Bewertung von Resilienz

Aus dem vorangegangenen Paragrafen geht ein Problem in der Literatur hervor. Da es bisher keine Normung des Begriffes Resilienz im Kontext der Produktion gibt, sind die Definitionen breit gestreut. Eine Begriffsnormung könnte die akademische Entwicklung des Themenkomplexes vorantreiben und dazu beitragen, dass Literatur besser aufeinander aufbauen kann. Auch die konkrete Modellentwicklung, welche schlussendlich in Industrieanwendungen verwendet werden können, würde durch eine Generalisierung des Grundkonzepts begünstigt werden.

Nicht zuletzt durch die fehlende Normung des Begriffs, ist die Messung und Bewertung von Resilienz eine komplexe Aufgabe. Die in der Literatur nicht abschließend geklärte Frage, welche Komponenten zu Resilienz gehören, erschweren die Konzeption eines allumfänglichen Bewertungsschemas der Resilienz eines Produktionssystems. Einen ersten Anhaltspunkt liefern Peukert et al. (2023), die in ihrer Arbeit unter anderem die Evaluation von Robustheit in Produktionen betrachten. Dabei definieren sie Robustheit als „the insensitivity to changes of the environment and can be regarded as a compromise between high and stable performance“ (Peukert et al. 2023, S. 416). Als mögliche Metrik für die Robustheit eines Prozesses nutzen die Autoren den Leistungsunterschied zwischen einem gestörten und einem unberührten Prozess sowie die Zeit, in der ein Leistungsverlust vorliegt. Da die Robustheit eine Komponente der Systemresilienz darstellt könnten bereits entwickelte Ansätze zur Evaluation der Robustheit oder anderen Komponenten der Resilienz dazu beitragen, ein Bewertungsmodell der Systemresilienz zu entwickeln.

Darüber hinaus kann in der Recherche nur eine Arbeit identifiziert werden, welche ein Modell zur Bewertung der Resilienz eines Produktionssystems entwickeln (Hosseini et al. 2016). In dieser Arbeit greifen die Autoren auf Bayessche Netzwerke zu Berechnungszwecken zurück und nutzen als Metrik das Verhältnis der wiederhergestellten Produktionsleistung und dem potenziellen Produktionsverlust im Falle einer Störung. Ein vollkommen resilientes System würde nach dieser Metrik keinen Verlust der Produktionskapazität im Falle einer Störung aufweisen und somit einen Wert von 100% aufweisen. Diese Metrik würde jedoch die Anpassungsfähigkeit eines Systems, was als Kernaspekt der Resilienz zu verstehen ist (Steinmeyer und Metternich 2023) nur bedingt wiedergeben und eher als Metrik der

Robustheit fungieren. Die vorgestellte Metrik weist Ähnlichkeiten zum Vorgehen von Peukert et al. (2023) zur Evaluation von Robustheit auf, was diese These noch weiter stützt. Das Rahmenkonzept, was von Hosseini et al. (2016) vorstellen greift über die zuvor vorgestellte Definition von Resilienz als Kapazität mit einer absorptiven, adaptiven und wiederherstellenden Komponente eine interessante Herangehensweise auf, weist aber dennoch gewisse Mängel auf. Dem vorgestellten Vorgehen fehlt es zum einen an einem gewissen Grad an Autonomie, da es sehr stark auf der Eingliederung von Expertenmeinungen zur Identifikation von Risiken und Gegenmaßnahmen im Produktionsprozess beruht. Diese Einbeziehung von Systemoperatoren macht die Ergebnisse sehr subjektiv und offen für fehlerhafte Einschätzungen. Darüber hinaus ist die Erkennung und Abwendung von Risiken gerade die Aufgabe eines resilienten Produktionssystems (Sheth und Kusiak 2022). Die Befragung von Systemoperatoren zur Identifikation von Risiken eliminiert somit einen zentralen Aspekt, welcher von einem resilienten System übernommen werden sollte. Zum anderen setzt die alleinige Betrachtung von einer Störungssituation eine verengte Sicht auf die Resilienz eines Systems voraus. Neben dem Umgang mit Störungen lässt sich die Resilienz auch im ungestörten Umfeld eines Produktionssystems beobachten. Hierbei muss die Resilienz des Systems über dessen Flexibilität und seine Anpassbarkeit an veränderte Anforderungen bewertet werden (Leng et al. 2023). Jedoch ist die Bewertung der Flexibilität eines Produktionssystems eine eher schwer zu quantifizierende und subjektive Metrik, da der notwendige Flexibilitätsgrad je nach Produktionssystem oder Industrie abweicht. Die Gestaltung eines Job Shop muss schon per Definition eine gewisse Flexibilität aufweisen und ist somit nicht mit anderen Produktionssystemen wie einer Linienfertigung, die für ihren Betrieb nur ein beschränktes Maß an Flexibilität benötigt, zu vergleichen. Selbst im Vergleich von Job Shop Systemen untereinander wird deutlich, dass das benötigte Maß an Flexibilität vollkommen von der Industrie beziehungsweise dem fertigenden Betrieb abhängt. Aufgrund der angeführten Subjektivität der Bewertung wäre die zuvor bei dem Vorgehen von Hosseini et al. (2016) kritisierte Eingliederung von Expertenmeinungen in den Bewertungsprozess nötig.

Leng et al. (2023) widmen sich in einem Unterkapitel ihrer Arbeit der Evaluation der Resilienz von Decentralized Autonomous Manufacturing Netzwerken, in welchem sie aktuelle Methoden in der Literatur identifizieren. Dabei teilen sie die Methoden in qualitative und quantitative Methoden ein, wobei einige dieser Methoden nicht dezidiert zur Evaluation von Resilienz entwickelt sind. Diese Methoden gliedern die Autoren dabei wie folgt:

„The qualitative ways include 1) a conceptual framework that provides best practices, and 2) semi-quantitative metrics that provide expert evaluation of various qualitative features of resilience. The quantitative ways include: 1) general methods that provide domainagnostic metrics to evaluate resilience in different implementations, and 2) structural-based modeling methods that capture domain-specific representations of the resilience“ (Leng et al. 2023, S. 107).

Diese Unterteilung gliedert sich in das zuvor diskutierte Vorgehen ein und unterstützt die über eine quantitative Evaluierung des Prozesses heraus auch die qualitative Bewertung von Parametern, wie der Flexibilität oder Adaptivität des Systems.

Darüber hinaus kann auch die Evaluation des Reinforcement Learning Modells, wenn diese im zu bewertenden Produktionssystem vorhanden sind, eingesetzt werden. Hierzu liefern Kuhnle et al. (2019b) innerhalb ihrer Designmethodik ein Beispielhaftes Vorgehen zu der Evaluation eines Reinforcement

Learning basierten Agenten. In diesem werden Experimente innerhalb des Digital Twins des betroffenen Systems durchgeführt. Diese können Aufschluss über die Lernfähigkeit des Modells geben, indem es die Geschwindigkeit und Anzahl an Iterationen, die für die erfolgreiche Anpassung des Systems auf ein angemessenes Leistungslevel nötig sind, widerspiegeln. Ebenso könnte das Reinforcement Learning basierte Modell gegenüber Benchmark Verfahren, wie anderen Algorithmen oder Heuristiken getestet werden. Dadurch lässt sich die Anpassbarkeit und Leistung eines zentralen Elements in der Produktionssteuerung evaluieren, was schlussendlich zur Erhöhung der Resilienz eines Systems beitragen kann.

Abschließend stellt sich die Frage, inwiefern die Erfassung der Resilienz als Ganzes nötig ist. Stattdessen könnte es ausreichen, einzelne Systemparameter, wie Durchlaufzeiten oder Produktionsmengen in störungsbehafteten Szenarien empirisch nachzuweisen, um so Vergleiche zwischen verschiedenen Produktionssteuerungen zu ziehen. Dadurch könnten bestehende Methoden aus der Literatur, die diese Komponenten betrachten einfach weiter benutzt werden und sind variabel auf individuelle Systeme anwendbar. Des Weiteren ist die Quantifizierung der Resilienz eines Systems in einer absoluten Metrik nur für die Bewertung des betroffenen Produktionssystems geeignet. Ein Vergleich der Resilienz zwischen verschiedenen Produktionssystemen wird durch die individuellen Anforderungen für die Adaptivität und Flexibilität des Systems schwer zu erreichen sein.

5.2 Aktueller Stand der Technik in Production Planning and Control

Dieses Unterkapitel widmet sich dem aktuellen State of the Art in der Produktionssteuerung. Dafür werden die in der Literatur verwendeten Technologien und Methoden zur Integration von Resilienz sowie die Konfigurationen von autonomen Produktionssystemen näher beleuchtet. Die Integration von künstlicher Intelligenz ist ein Thema, was besonders in den Fokus rückt, da sich 20 der 26 identifizierten Arbeiten mit einer Integration von Machine Learning in die Produktionssteuerung beschäftigen. Dabei wird das Kapitel wieder nach der in Kapitel 3 etablierten Gruppierung der Literatur aufgeteilt. Hierbei stellt das erste Unterkapitel basierend auf der recherchierten Literatur aktuelle Technologien vor, die zur Steigerung der Resilienz eines Produktionssystems durch die Eingliederung von Wartungsmaßnahmen in den Produktionsplan und der Überwachung von Gesundheitszuständen des Systems beitragen. Das zweite Unterkapitel stellt Methoden zur Autonomisierung von Scheduling und Dispatching Aufgaben sowie die Integration des Faktors Mensch in den Planungsprozess vor. Am Ende dieser beiden Unterkapitel wird jeweils auf die Validierung der Modelle, welche die Autoren in ihren Arbeiten anführen, eingegangen. Während sich die ersten beiden Abschnitte mit der konkreten Implementierung von Maintenance und Scheduling in den Produktionsprozess auseinandersetzen, greift das dritte Unterkapitel die Systemperspektive auf. Bei dieser werden der aktuelle Stand sowie die Entwicklungsrichtung dargelegt, welche die recherchierte Literatur widerspiegeln. Dieses Unterkapitel greift unter anderem Themen wie Systemarchitektur und -betrachtung sowie Methoden zur Steigerung der Resilienz von Produktionssystemen auf.

5.2.1 Maintenance

In diesem Teil des Kapitels werden die aktuell genutzten Technologien zur Integration von Resilienz in den Wartungsprozess, welche sich aus der Literaturrecherche ergeben, zu einem Gesamtmodell zusammengefasst, welches den aktuellen Stand der Technik widerspiegeln soll. Obwohl in diesem Teil der Recherche nur Elbasheer et al. (2022) direkten Bezug zur Integration von Resilienz nehmen, liefern alle Arbeiten einen Beitrag zur resilienten Gestaltung von Produktionssystemen.

Die Basis dafür liefert die Integration von Daten aus dem Produktionsprozess. Hierfür lassen sich digitale Modelle wie der Digital Twin verwenden (Elbasheer et al. 2022; Neto et al. 2021), die den Produktionsprozess in einem virtuellen Modell widerspiegeln. Eine Grundvoraussetzung dessen ist die Ausstattung der Produktionsumgebung mit Sensoren. Diese werden unter anderem zum Messen von Telemetriedaten der Maschinen wie Drehzahl oder Spannung sowie der Erfassung der Produkte in der Produktionsanlage durch Radio Frequency Identification Chips. Neben der abbildenden Funktion nutzen die Autoren den Digital Twin als Umgebung, in der sie Simulationen ausführen. Die Ergebnisse der Simulationen lassen sich zum Treffen von Vorhersagen (Neto et al. 2021) und zur Erstellung von Trainingsdaten, durch die sich ein Algorithmus, der auf Machine Learning basiert, dauerhaft verbessern lässt (Elbasheer et al. 2022).

Aufbauend auf der Datenintegration durch Digital Twins lassen sich Systemzustände vorhersagen und überwachen. Zur Vorhersage von Gesundheitszuständen wird als Basis die Remaining Useful Life (Elbasheer et al. 2022; Zonta et al. 2022) genutzt. Diese gibt Aufschluss über den Zustand von Maschinen und Werkzeugen, welche über Zeit degradieren. Bereits durch die Bestimmung der Remaining Useful Life lässt sich die Robustheit eines Systems erhöhen, da sie einen Aufschluss über Abweichungen von den Herstellerangaben bei einer zeitbasierten Wartung der Produktionsanlage. Dies verhindert den Ausfall von Maschinen und trägt zur Erhaltung der Produktqualität bei. Die Bestimmung der Remaining Useful Life kann basierend auf Machine Learning Algorithmen stattfinden. Dazu lassen sich aus dem Produktionsprozess gewonnene Telemetriedaten verwenden. Diese müssen in Verbindung mit einem Maschinenausfall stehen, um somit ein Klassifikationsproblem zur Anwendung für die Supervised Learning Methode zu bilden (Zonta et al. 2022). Hierbei ist jedoch eine hohe menschliche Intervention nötig, um die Klassifizierung der Daten zu überwachen. Das trainierte Modell ist damit in der Lage, Muster in den Telemetriedaten des Produktionsprozesses zu erkennen und einen Ausfallzeitpunkt der Maschine hervorzusagen.

Das Kernthema dieses Unterkapitels ist die Abkehr von zeitbasierten, präventiven Wartungsmaßnahmen hin zu auf zustandsbasierter Wartung (Zonta et al. 2022), welche statt fester Zeitintervalle den Vorhersagen über den Zustand der Komponenten als Parameter zur Eingliederung von Wartungsmaßnahmen in den Produktionsplan nutzt. Hierbei kann das zuvor vorgestellte Remaining Useful Life degradierender Maschinenkomponenten genutzt werden. Hierzu wird von Zonta et al. (2022) das Konzept Predictive Maintenance and Scheduling eingeführt. Predictive Maintenance beschreibt dabei die Vorhersage von Wartungszeitpunkten basierend auf dem Gesundheitszustand der Komponenten, welche in diesem integrierten Ansatz in den Produktionsplan eingepflegt werden. Währenddessen stellen Elbasheer et al. (2022, S. 1) Prescriptive Maintenance als „highest digitization level of the Smart maintenance paradigm“ vor. Dieser Ansatz soll über die reine Vorhersage potenzieller Maschinenausfälle

hinaus die in Anblick der Systemeffizienz besten Handlungsempfehlungen ausgeben. Im Kern verfolgen beide Konzepte das gleiche Ziel, welches die Integration von Predictive Maintenance in den Produktionsplan eines Unternehmens ist.

Die Integration der Predictive oder Prescriptive Maintenance gewonnenen Erkenntnisse geschieht in einem Decision Support Agenten (Neto et al. 2021; Elbasheer et al. 2022), welcher als Schnittstelle zwischen Mensch und Maschine dient. Dieser trifft auf der Basis der möglichen Wartungsmaßnahmen und potenziellen Scheduling Strategien eine Entscheidung für eine bestmögliche Kombination auf beiden Ebenen (Elbasheer et al. 2022). Für die Vorhersage von potenziellen Produktionsplänen sowie nutzbaren zeitlichen Freiräumen eignet sich laut Morariu et al. (2020) ein Agent, welcher auf Long Short Term Memory Netzwerken basiert. Diese sind eine Unterkategorie der Recurrent Neural Networks, welche sich gut für Vorhersagezwecke eignen und mit Daten aus dem Produktionsprozess trainiert werden können. Die vom Decision Support Agenten vorgeschlagene Kombination an Maßnahmen aus Wartung und Planung kann im Digital Twin simuliert und bewertet werden. Die Bewertung trägt durch den Einsatz von Reinforcement Learning dazu bei, die Entscheidungsfindung des Decision Support Agenten dauerhaft zu verbessern.

Die Integration der von den Autoren in der ausgewählten Literatur vorgestellten Modelle erlaubt es, den aktuellen Stand der Technik abzubilden. Dieser ermöglicht die Integration von Robustheit durch die Machine Learning basierte Vorhersage von Maschinenlebensdauern sowie eine Erhöhung der Adaptivität und Agilität des Systems durch integrierte Planungsmaßnahmen. Dabei nimmt die Unterstützung der menschlichen Entscheidungen eine zentrale Rolle ein und mildert so eine zentrale Fehlerquelle im Entscheidungsprozess ab. Identifizierte Lücken auf technischer und Modellebene sowie ein Ausblick auf mögliche Weiterentwicklungen sollen im folgenden Unterkapitel 5.3 dargelegt werden.

Im Folgenden erfolgt eine Evaluation der Validierung der Modelle, welche die Autoren in ihren Arbeiten genutzt haben. Neto et al. (2021) können ihr Decision Support System durch die Anwendung in einem realen Fallbeispiel aus der Möbelproduktion validieren. Währenddessen können Elbasheer et al. (2022), Morariu et al. (2020) und Zonta et al. (2022) ihre Modelle lediglich in experimentellen Simulationen ohne die Integration von realen Industrieanwendungen demonstrieren. Zwar werden für alle Modelle zumindest experimentelle Validierungen durchgeführt, jedoch besteht nur eine geringe Validierung in echten Industrieszenarien.

5.2.2 Scheduling & Dispatching

Dieses Unterkapitel behandelt den aktuellen Stand der Technik zu den Themen Scheduling und Dispatching. Dazu werden die von den Autoren vorgestellten Modelle, welche in 4.2 dargelegt werden, auf Komponenten analysiert, welche zur Gestaltung eines Resilienten Produktionssystems beitragen. Dabei werden zum einen die im vorherigen Unterkapitel angesprochenen Technologien wie der Digital Twin sowie die Machine Learning basierte Auslegung von Produktionsplänen und die hierfür verwendeten Algorithmen dargelegt. Zum anderen wird die Schnittstelle zwischen Menschen und Maschinen sowie die allgemeine Rolle des Menschen in einer resilienten Produktionsplanung etwas näher beleuchtet. Im Allgemeinen beziehen sich die Autoren bei der Erstellung ihrer Modelle auf den Einsatz in flexiblen Produktionsumgebungen wie Job Shops oder zellenbasierte Fertigungssysteme.

Ähnlich wie im vorangegangenen Unterkapitel bildet auch bei Scheduling und Dispatching Anwendungen der Digital Twin die Grundlage zur umfangreichen Erfassung von Daten aus dem Produktionsprozess. Greis et al. (2022), welche die einzigen Autoren in dieser Gruppierung sind, die sich mit dem Thema Resilienz des Produktionssystems auseinandersetzen, stellen hierbei ein Konzept des digital Twin vor, welches durch die Integration von Machine Learning in den Digital Twin kognitive Eigenschaften in sich vereinen soll. Dadurch soll der Digital Twin über die einfache Erfassung und Verarbeitung von Daten hinaus Fähigkeiten wie Lernfähigkeit, Gedächtnis und Problemlösung sowie ein Bewusstsein über Kontext, Zeit und Ziele mit sich bringen. Dieses Konzept könnte sehr stark zu der Gestaltung eines resilienten Produktionsprozesses in allen Dimensionen beitragen.

Neben der Erfassung von Daten spielt die Schnittstelle zwischen Maschine und Mensch sowie die Einbeziehung des Menschen in die Produktionssteuerung und den Planungsprozess eine wichtige Rolle. Hierzu nutzen Greis et al. (2022) Augmented Reality, welche es ermöglicht, die Sicht des Menschen auf den Produktionsprozess, beispielsweise durch die Verwendung von Smart Glasses zu erweitern. Hierbei lassen sich laut den Autoren aufbereitete Metriken aus dem Produktionsprozess durch den Digital Twin interaktiv auf den Produktionsprozess abbilden. Ebenso könne die Entscheidungsfindung des Machine Learning basierten Agenten dadurch überblickt und bewertet werden, was ein zentraler Punkt zur Gestaltung einer resilienten Produktionsplanung ist, da dadurch eine stetige Güte des Modells gewährleistet werden kann und gegebenenfalls Anpassungen bezüglich der Entscheidungsfindung getroffen werden können.

Des Weiteren ist nicht nur die Einbeziehung des Menschen als Schnittstelle wichtig, sondern auch die Erfassung von dem Faktor Mensch als Ressource im Produktionsprozess. Hierzu nutzen Liu et al. (2023) einen Multiagenten Ansatz, welcher einen dedizierten Agenten für das Scheduling von Arbeitskräften in einem Flow Shop besitzt. Laut den Autoren kann dieser dedizierte Agent die Ermüdung und Verfügbarkeit von Arbeitskräften beachten und in seine Entscheidungsfindung mit einbeziehen. Darüber hinaus sei er in der Lage, die Fähigkeiten der einzelnen Arbeitskräfte zu überblicken und diese bei der Entscheidung über eine optimale Jobzuweisung zu beachten. Das für den verwendeten Agenten genutzte Deep Reinforcement Learning Modell für den beruht auf einem Attentionbased Neural Network. Die Integration von Fähigkeiten und Ermüdungszustand von Arbeitern macht es möglich, den kontinuierlichen Fluss von Produkten in Produktionssystemen, wie dem Job Shop oder zellenbasierten Fertigungen aufrechtzuerhalten und trägt somit zur Robustheit und Adaptivität der Planung bei. Darüber hinaus lassen sich durch die Vermeidung übermüdeter Arbeitskräfte Fehler in der Anwendung vermeiden. Dadurch lassen sich Risiken für abnehmende Produktqualität oder das Eintreten von Arbeitsunfällen vermeiden, was die Robustheit des Prozesses zusätzlich steigert.

Für das eigentliche Erstellen von Produktionsplänen sowie dem Dispatching kommen Multiagentensysteme in Einsatz. Diese sollen auf Methoden aus dem Reinforcement Learning beruhen, da eine rein regelbasierte Produktionssteuerung, welche mit der Anwendung von Heuristiken arbeitet, dem Einsatz in flexiblen Produktionsumgebungen wie Job Shops nicht gerecht werde und auch nicht das volle Potenzial ausschöpfen, was diese Produktionssysteme bieten (Hofmann et al. 2020). Eine der Schwierigkeiten, die beim Training der Machine Learning basierten Modelle entsteht, ist, dass für das Training genutzte Parameter wie die Durchlaufzeit erst zum Ende des Prozesses vorhanden sind, wodurch eine zeitliche Diskrepanz entsteht (Hofmann et al. 2020). Um diese zu umgehen werden für das Training

der Modelle Algorithmen wie (Deep-) Q-Learning (Hofmann et al. 2020; Stricker et al. 2018) eingesetzt, die aus der Gruppe des Temporal Difference Learnings stammen. Jedoch können auch alternative Algorithmen wie Proximal Policy Optimization oder Trust Region Policy Optimization (Kuhnle et al. 2019a; Kuhnle et al. 2019b) zum Einsatz kommen.

Im Folgenden erfolgt eine Evaluation über die Validierung der Modelle, welche die Autoren in ihren Arbeiten genutzt haben. Während Hofmann et al. (2020) ihr Modell lediglich in einer experimentellen Simulation darlegen können, nutzen Liu et al. (2023) einen realen Industriefall aus der Pharmaindustrie zur Validierung ihres Modells. Greis et al. (2022) berichten, dass ein an ihr Konzept angelehntes System zur Darstellung von Prozessdaten bereits in einer Siemensfabrik getestet wird. Da Stricker et al. (2018), Kuhnle et al. (2019a) und Kuhnle et al. (2019b) ein sehr stark aufeinander aufbauendes Konzept verfolgen, kann man sagen, dass der schlussendlich entstandene Leitfaden zur Implementation von Reinforcement Learning eine sehr gute, auf einem Experiment und einer konkreten Industriefallstudie basierende Validierung besitzt. Zusammenfassend lässt sich sagen, dass die Validierung der Modelle in diesem Bereich deutlich Praxisnähe ausfällt als im vorangegangenen Unterkapitel.

5.2.3 Systembetrachtung

Dieses Unterkapitel ist anders aufgebaut als seine beiden Vorgänger. Statt der Applizierung der identifizierten Ansätze zur resilienten Gestaltung autonomer Produktionssteuerung und der anschließenden Bewertung der Validierung der jeweiligen Ansätze werden in diesem Abschnitt Erkenntnisse erläutert, die die systemische Sicht betreffen. Hierbei werden einzelne Modelle aus der Literatur hervorgehoben, die in den meisten Fällen keine praktische Applikation wie die Vorhersage von Maschinenlebensdauern anstreben. Stattdessen dient dieses Unterkapitel dazu, die aktuelle Entwicklung von Produktionssystemen auf Modellebene bezüglich ihrer Organisationsstruktur zu betrachten.

Wie aus den beiden vorangegangenen Unterkapiteln hervorgeht, spielt die Integration von Daten aus dem Produktionsprozess eine zentrale Rolle zur Gestaltung resilenter Produktionssysteme. Dabei spielt der Digital Twin eine zentrale Rolle und kann durch die Integration von Daten in den Steuerungsprozess, aber auch bereits durch die Sichtbarkeit dieser Risiken für den Betrieb vermindern (Sheth und Kusiak 2022). Jedoch ist hierbei eine klare Unterscheidung zu treffen, welche in der Literatur oft missachtet wird ist die Unterscheidung zwischen Digital Twin und Digital Shadow, welche nicht zur Rückführung von Daten in den Produktionsprozess geeignet ist, jedoch für einige Anwendungsfälle wie Simulationen und der Darstellung von Metriken ausreicht (Ehrhardt und Hoffmann 2020). Während die Integration von Digital Twins und Digital Shadows in moderne Produktionsbetriebe bereits zur Gestaltung von resilienten Systemen beiträgt, ist deren Gestaltung wohl genauso wichtig. Die Integration von robusten Sensoren in den Produktionsprozess ist daher für die Verlässlichkeit der Daten wichtig (Möhring et al. 2020). Des Weiteren wenden Leng et al. (2022) mit Lösungen aus dem Bereich Blockchain neue Methoden an, um den Verkehr von Daten sicherer zu machen. Dafür greifen die Agenten in dem von ihnen vorgestellten Modell auf Blockchain basierte Peer-to-Peer Kommunikation zurück. Hierbei können kritische Informationen im Blockchain Netzwerk gespeichert werden. Ein großer Vorteil, welchen die Integration dieser Methode laut den Autoren bietet, ist dabei die Manipulationssicherheit der Daten, welche die

Authentizität garantiert. Damit wird gewährleistet, dass das System mit unverfälschten Daten arbeitet, was die Resilienz in diesem Bereich erhöhen könnte.

Nach der Definition, welche Steinmeyer und Metternich (2023) für die Resilienz in Bezug auf Wertströme nutzen, ist die Anpassungsfähigkeit eines Systems eine zentrale Eigenschaft resilenter Systeme (Möhring et al. 2020). Hierbei lässt sich die Fähigkeit sich selbst ohne die Interaktion von Operatoren als besonders wichtig einordnen. Dies ist ein Punkt, welcher oft in aktueller Literatur aufgegriffen wird. Brettel et al. (2016) benennen dafür vier Voraussetzungen, welche ein System erfüllen muss, um sich selbst zu adaptieren. Hierbei benennen sie Cognition als Fähigkeit, Informationen zu verarbeiten, wofür in der Regel die zuvor angeführten Digital Twins und Digital Shadows sowie der Einsatz von Machine Learning basierten Algorithmen infrage kommen. Des Weiteren wird Autonomy als Fähigkeit, Aktionen ohne äußere Eingriffe im Rahmen der Systemfreiheitsgrade auszuführen, genannt. Diese Funktion nehmen in aktuellen Produktionssystemen meist Multiagentensysteme ein, die ihr Handeln auf Machine Learning basiertem Training oder dem Einsatz von Heuristiken stützen. Diese Freiheitsgrade bestimmen sich laut den Autoren aus der Flexibilität und der Variabilität des Systems, welche die weiteren zwei Voraussetzungen für sich selbst adaptierende Systeme darstellen.

Jedoch ist die reine Selbstanpassung eines Systems kein Garant für Resilienz. Die Selbstanpassung findet in vielen Fällen als Reaktion auf eintretenden Ereignissen oder Störungen in der Umwelt des Unternehmens auf. Statt der Reaktion empfiehlt sich laut einigen Autoren die proaktive Selbstanpassung von Produktionssystemen. Dabei nutzen (Klaas et al. 2013) Vorhersagemodelle, welche auf Basis von der Entwicklung aktueller Systemparameter zukünftige Umweltzustände abschätzen. Auf deren Basis werden in Simulationen des Systems Datensätze erzeugt, welche dem Training eines Machine Learning basierten Modells zur Steuerung von Produktionssystemen dienen soll. Systeme wären so in der Lage, bereits vor dem Eintreten störender Situationen für diese gewappnet zu sein und somit robust und agil auf diese zu reagieren. Nach Sheth und Kusiak (2022) soll sich die Betrachtung des Produktionssystems hin zu dem eines Complex Adaptive Systems entwickeln und dabei neben adaptiven fast evolutionäre Züge aufweisen.

Eine ähnliche Perspektive führen dazu Byrne et al. (2021) auf. Sie stellen die These auf, dass sich technische Systeme aktuell in einer Konvergenz hin zu lebenden Organismen befinden. Die Bio-Inspiration ist dabei ein interessanter Aspekt, welcher sich zur Entwicklung resilenter und adaptiver Produktionssysteme der Zukunft zu entwickeln eignen könnte. Die Konvergenz kommt laut den Autoren durch einen technologischen Pull oder einen biologischen Push zustande und soll über die Integration von Eigenschaften lebender Wesen in den Produktionsprozess bedeuten.

Ein weiterer Faktor, der für die Selbstanpassung von Systemen wichtig ist, spielt die Standardisierung von Soft- und Hardware. Jedoch sind standardisierte Softwarelösungen in diesem Bereich der Forschung noch rar gesät. Die meisten der vorgestellten Modelle betrachten Individuallösungen, welche schwer auf andere Systeme übertragbar sind Konzepte. Module, die mit einer einfachen Adaptierbarkeit entwickelt werden, gibt es so gut wie keine (Di Orio et al. 2015). Hierbei ist es außerdem wichtig, dass Produktionssysteme, welche heutzutage meist aus global verstreuten Einheiten bestehen, untereinander kommunizieren können. Qin und Lu (2021) nennen diesen Ansatz Plug-and-Produce. Dabei sollen zentrale Produktionssysteme in der Lage sein, mit Machine Learning basierten Algorithmen über lokale Maschinen

und Ressourcen zu verfügen. Dies soll die Agilität und Adaptivität über die Modellebene von lokalen Systemen heraus für reale Produktionsbetriebe, welche heute meist einen Netzwerkcharakter aufweisen, gewährleisten.

Der soeben angesprochene Netzwerkcharakter von produzierenden Unternehmen stellt neben der Selbstanpassung von Systemen einen weiteren zentralen Themenschwerpunkt in der aktuellen Literatur bezüglich der Weiterentwicklung von Produktionssystemen. Dabei müssen neben der Betrachtung von ganzen Prozessketten (Möhring et al. 2020) weitere globale Zusammenhänge neben der eigentlichen Steuerung von Produktion in die Planung mit einbezogen werden. Hierbei spielen vor allem Schwankungen bei der Nachfrage der hergestellten Produkte und die globale Logistik eines Unternehmens, was unter anderem Transporte und Lagerhaltung betrifft (Sheth und Kusiak 2022; Peukert et al. 2023) eine große Rolle. Der Trend zu flexiblen Produktionssystemen wie Job Shops oder zellenbasierter Fertigung, der mit der Digitalisierung von Produktionsprozessen und der Integration von Machine Learning basierten Steuerungssystemen einhergeht, ist in der aktuellen Literatur klar zu erkennen. Dieser geht meist mit einem Distributed Production Control Ansatz einher. Dieser Ansatz eignet sich sehr gut dazu, in lokalen, flexiblen Produktionsbetrieben Entscheidungen zu treffen und dabei die Potenziale von Machine Learning basierten Multiagenten Systemen zur Steuerung und Planung voll auszunutzen. Jedoch wird vor allem in der Netzwerkbetrachtung deutlich, dass diese verengte Sicht der Systeme nicht ausreicht, um global- und netzwerkoptimale Entscheidungen für vernetzte Produktionssysteme zu treffen (Peukert et al. 2023). Dies betrifft sowohl die netzwerkoptimale Festlegung von Produktionsplänen als auch das Treffen von Entscheidungen, welche die Robustheit und Resilienz des Systems betreffen.

Antons und Arlinghaus (2021) vergleichen in ihrer Arbeit Centralized und Distributed Production Control Ansätze, deren Agenten über die Integration von Maximum Likelihood Estimators die Lernfähigkeit über lokale Zustände der einzelnen Maschinen erhalten. Dabei kommen sie zu dem Schluss, dass der Centralized Production Control Ansatz eine bessere Systemperformance als der dezentralisierte Ansatz erreicht. Jedoch kommen durch die hohe Komplexität der zu bewältigenden Optimierungsaufgabe bei dem zentralisierten Steuerungselement deutlich höhere Rechenzeiten zustande. Zusätzlich liegt bei diesem Ansatz eine deutlich höhere Streuung der Ergebnisse vor, was durch den geringeren Fokus auf lokale Gegebenheiten zustande kommt. Allgemein sorgt solch ein Ansatz neben der Bündelung eines Ausfallrisikos an einer zentralen Stelle zu weniger Flexibilität und Adaptivität des Produktionssystems. Hingegen versuchen Qin und Lu (2021) in ihrer Arbeit zum Self-Organizing Manufacturing Network einen Ansatz zu entwickeln, welcher die Vorteile von Distributed und Centralized Production Control Systemen vereint. Das Partially Distributed Control System soll laut den Autoren dazu beitragen, sowohl netzwerkoptimale Entscheidungen zu treffen als auch die Möglichkeiten der Netzwerkstruktur und lokalen, flexiblen Produktionsstätten voll ausschöpfen.

Des Weiteren lassen sich Ansätze wie von Leng et al. (2023) in dezentralisierte Produktionssysteme einführen. Sie stellen in ihrer Arbeit ein Modell vor, welches weitere Blockchain Technologien in die Steuerung von Produktionsprozessen integrieren soll. Hierbei kann die Kommunikation zwischen Agenten in der Produktionsumgebung über Smart Contracts abgewickelt werden. Diese können genutzt werden, um durch das Blockchain Netzwerk Jobs zu verteilen. Zudem setzen sie die auf Blockchain 3.0 (Decentralized Application) basierende Technologie Decentralized Autonomous Organization zur

Anwendung auf Produktionssysteme ein, was diese resilenter gestalten soll. Dieses Paradigma, was sie als Decentralized Autonomous Manufacturing bezeichnen, soll dabei folgende Eigenschaften in sich vereinen:

„1) the manufacturing process information is uploaded to a shared ledger, and the whole product lifecycle can be traced, 2) proactively configure production capacity to deal with unpredictable orders, 3) performing the decentralized collaborative decision-making on task dispatching, and 4) self-organizing (proactively rescheduling and reconfiguration) under the severe disturbances/disruptions/attacks in the production process instead of stopping the manufacturing system completely“ (Leng et al. 2023, S. 98).

Durch die Integration von Blockchain Technologien könnte somit sowohl ein Schritt in die Richtung von resilienten Produktionssystemen als auch in Richtung Industrie 5.0 bieten.

Ein weiteres Thema, welches in den letzten Jahren an Popularität gewinnt, ist Circular Manufacturing. Diese Systeme nutzen Recycling und Remanufacturing (Paraschos et al. 2022), was die Aufbereitung von Abfällen und Produkten niederer Qualitätsstufen beinhaltet. Diese Aktivitäten können stark zu der Effizienz eines Betriebes beitragen. Diese Systeme profitieren sehr stark von der Flexibilität und Adaptivität eines Produktionssystems und somit von der Resilienz, da das System somit in der Lage ist, seine Aktivitäten nach den aktuellen Bedarfen für Produktion, Recycling und Remanufacturing Maßnahmen umzustellen.

Ein letzter Punkt ist die Steigerung der Effizienz mit der Machine Learning basierte Multiagenten Systeme zur Produktionssteuerung arbeiten. Hierbei wenden Paraschos et al. (2022) zusätzlich zu Reinforcement Learning ad-hoc Produktionsregeln ein, mit denen die Agenten arbeiten können. Dabei kommen sie zu dem Ergebnis, dass diese Integration eine Steigerung der Systemleistung zufolge hat. Das System schafft es trotz schwankender Produktnachfrage dauerhaft adäquate Lagerbestände von Produkten zu halten und Überproduktion zu vermeiden. Darüber hinaus wird die Kosteneffizienz durch eine Erhöhung der Recyclingmaßnahmen im System erreicht. In einem weiteren Ansatz stellen Mukherjee et al. (2022) den Einsatz von Methoden aus der Machine Learning Resilience vor. Dabei wird über Adversial Attacks die Simulation eines Systems angegriffen, um so krisenartige Umwelteinflüsse zu simulieren. Die sich aus der Simulation ergebenden Daten lassen sich daraufhin zum Training eines resilienten Machine Learning Algorithmus einsetzen, welcher durch die genutzten Trainingsdaten eine adäquate Vorbereitung auf Disruptive Situationen besitzt.

Zusammenfassend lässt sich die aktuelle Entwicklung in der Literatur als Paradigmenwechsel von der Steuerung einzelner autonomer Systeme hin zu der Betrachtung von globalen Produktionsnetzwerken und netzwerkoptimalen Entscheidungen klassifizieren. Dabei rückt neben der Autonomisierung der verteilten Produktionssysteme deren zentrale Steuerbarkeit durch standardisierte Lösungen in den Fokus. Auch deren proaktive Selbstanpassung durch eine Integration von Datenströmen, die über den Produktionsprozess hinaus auch seine Umwelt betreffen und den Einsatz von Machine Learning basierten Steuerungssystemen ist ein Kernthema der aktuellen Literatur zu resilienten Produktionssystemen. Jedoch steckt die Nutzung von Resilienz noch in den Kinderschuhen und besonders die Entwicklung resilenter Agentensysteme ist noch ein schwach ausgeprägtes Thema. Darüber hinaus entwickeln sich neue Produktionskonzepte wie Circular Manufacturing, welche neben gewinnen in der Kosteneffizienz auch eine umweltfreundlichere Produktion versprechen. Während durch die bereits angeführten

Entwicklungen im Bereich der Produktionssysteme die vierte industrielle Revolution noch in vollem Gange ist, entwickeln sich auf Basis von Blockchain Technologien Modelle, die den Weg für resiliente Produktionssysteme in Richtung Industrie 5.0 weisen.

5.3 Lücken und Forschungsrichtungen

In diesem Unterkapitel werden in einem ersten Teil Lücken in der Forschung identifiziert, welche durch die Analyse der recherchierten Literatur sowie der Betrachtung des aktuellen Stands der Technik und Forschung deutlich werden. Daraufhin wird ein Ausblick auf mögliche Forschungsrichtungen gegeben, die für zukünftige Projekte interessant sein könnten.

5.3.1 Lücken und Forschungsrichtungen

Bezüglich der Integration von Resilienz in aktuelle Produktionssysteme lassen sich in der aktuellen Literatur eindeutige Lücken aufzeigen. Ein erster Punkt ist hierbei die in 5.1 diskutierte Begriffsnutzung und Quantifizierung von Resilienz. Hierbei wird deutlich, dass es sich um ein in der Literatur noch recht junges Thema handelt. Während es keine Normung des Begriffes Resilienz gibt, lassen sich die Komponenten Robustheit, Agilität und Adaptivität sowie Selbstanpassung für Resiliente Systeme aus der aktuellen Literatur herausarbeiten. Hierbei werden einzelne Komponenten bei der Nutzung des Begriffes von vielen Autoren außen vorgelassen und es ergibt sich ein Begriffsverständnis in Betrachtung der Gesamtliteratur. Neben den Problemen bei der Begriffsdefinition ist die Quantifizierung der Resilienz eine vielschichtige Aufgabe, welche bis jetzt nicht hinreichend gelöst ist. Während die Resilienz in der Systembetrachtung bereits Einzug erhält, weisen konkrete Anwendungsmodelle für die Applikation in der Produktionssteuerung wie in 5.2.1, 5.2.2 einen sehr geringen Bezug auf die Resilienz des Systems auf. Darüber hinaus weisen genannte anwendungsbezogene Modelle eine geringe Validierung mit konkreten Fallbeispielen auf. Auch gibt es wenige Modelle, welche von Autoren als ein generell anwendbarer Leitfaden oder integrierbares Modul wie bei Kuhnle et al. (2019b), Peukert et al. (2023) oder Di Orio et al. (2015) verfasst werden. Auch fehlt es in der aktuellen Literatur an Vorgehen, welche zur Steigerung der Resilienz von Agentensystemen oder den ihnen zugrunde liegenden Machine Learning Modellen beitragen.

5.3.2 Ausblick Forschung

Basierend auf den zuvor identifizierten Lücken in der Forschung lassen sich einige interessante Richtungen für künftige Forschungsprojekte entwickeln. Ein erster Anhaltspunkt wäre hierbei die Normung und Evaluation von Resilienz auf den im vorangegangenen Kapitel erörterten Ebenen. Darüber hinaus könnte aufgrund der kleinen Repräsentation von Resilienz in konkreten Anwendungsmodellen für Produktionssteuerungen die Entwicklung einer resilienten, autonomen Produktionssteuerung inklusive

der Integration von realen Industriefällen eine gute Weiterentwicklung der aktuellen Literatur darstellen. Ein Hauptteil dieser Forschung könnte dabei von Methoden zur Gestaltung resilenter, Machine Learning basierter Agenten zur autonomen Produktionssteuerung handeln. Ein nächster Schritt wäre hierbei eine Eingliederung des im vorangegangenen Kapitel erörterten Netzwerkcharakters aktueller Produktionssysteme. Diese Forschungsmöglichkeiten könnten wie folgt aufeinander aufbauen:

- Definition und Evaluation von Resilienz autonomer Produktionssteuerungen.
- Methoden zur Integration von Resilienz in Machine Learning basierten Multiagentensystemen in der autonomen Produktionssteuerung.
- Integration eines resilienten Modells zur autonomen Steuerung von Produktions- und Wartungsplänen in der Industrie
- Die resiliente Steuerung autonomer Produktionsnetzwerke

6 Zusammenfassung

Die Umwelt und die Struktur von Unternehmen haben sich in dem letzten Jahrzehnt stark verändert. Durch ein dynamisches Umfeld, welches von Krisen wie Kriegen, Pandemien sowie den drohenden Folgen des Klimawandels geprägt ist, sind Produktionsprozesse steigenden externen Risiken ausgesetzt. Darüber hinaus sind Produzenten in Anblick von schrumpfenden Produktlebenszyklen und regional zu individualisierenden Produkten dazu genötigt, eine breite Produktpalette zu produzieren und diese regelmäßig anzupassen.

In diesem Kontext setzt sich diese Arbeit mit der Entwicklung moderner Produktionsprozesse zu autonomen und resilienten Systemen auseinander. Die Basis für dieses Vorgehen bietet eine systematische Literaturrecherche, durch die 26 wissenschaftliche Arbeiten für die Analyse des Themas ausgewählt werden. Die Kernthemen sind hierbei die Betrachtung von Maßnahmen zur konkreten Gestaltung sowie die Analyse der theoretischen Entwicklung von Modellarchitekturen resilenter und autonomer Produktionssysteme.

Zu diesem Zweck findet zuerst eine Begriffsklärung statt, bei der deutlich wird, dass die Verwendung des Begriffes Resilienz in weniger als der Hälfte der recherchierten Literatur einen Platz findet, obwohl alle Modelle zu einer Steigerung dieser beitragen. Dies ist besonders im Bereich der konkreten Anwendungsmodelle der Fall, bei denen nur zwei der 10 Arbeiten sich konkret auf die Resilienz des Systems beziehen. Im Bereich der Modellentwicklung ist der Begriff bereits viel weiter fortgeschritten, wobei auch hier keine eindeutige Definition des Begriffs zu finden ist. Als Kernkomponenten der Resilienz lassen sich hierbei die Fähigkeiten Robustheit, Agilität, Adaptivität und Selbstanpassung extrahieren.

Des Weiteren findet eine Synthese der im Kapitel Literaturanalyse der Arbeit dargelegten Inhalte der ausgewählten Arbeiten statt, welche den darauf basierenden, aktuellen Stand der Technik in den Bereichen Maintenance und Scheduling & Dispatching in zwei Modellen darlegt. Hierbei besitzen Machine Learning und Digital Twins eine hohe Anwendungsdichte für die Steigerung der Resilienz der Systeme. Darüber hinaus werden aktuelle Forschungsrichtungen und Trends in der Architektur moderner Produktionssysteme dargelegt.

Zusammenfassend lässt sich festhalten, dass der Begriff Resilienz im Kontext der Produktionsumgebung noch in der Entwicklung ist und es einer Vereinheitlichung und Möglichkeiten der Evaluation von Resilienz bedarf. Besonders in konkreten Anwendungsfällen, die mit realen Industriefällen arbeiten gibt es große Lücken und den Bedarf für weiterführende Forschungsprojekte.

Literaturverzeichnis

Literaturverzeichnis

- Antons, Oliver; Arlinghaus, Julia C. (2021): Adaptive self-learning distributed and centralized control approaches for smart factories. In: *Procedia CIRP* 104, S. 1577–1582. DOI: 10.1016/j.procir.2021.11.266.
- Arzi, Yohanan; Herbon, Avi (2000): Machine learning based adaptive production control for a multi-cell flexible manufacturing system operating in a random environment. In: *International Journal of Production Research* 38 (1), S. 161–185. DOI: 10.1080/0020275400189635.
- Berry, Michael W.; Mohamed, Azlinah Hj; Wah, Yap Bee (Hg.) (2020): Supervised and unsupervised learning for data science. Cham: Springer (Unsupervised and semi-supervised learning).
- Brennan, Robert W.; Norrie, Douglas H. (2001): Evaluating the performance of reactive control architectures for manufacturing production control. In: *Computers in Industry* 46 (3), S. 235–245. DOI: 10.1016/S0166-3615(01)00108-7.
- Brettel, Malte; Fischer, Felix Gabriel; Bendig, David; Weber, Anja Ruth; Wolff, Bartholomäus (2016): Enablers for Self-optimizing Production Systems in the Context of Industrie 4.0. In: *Procedia CIRP* 41, S. 93–98. DOI: 10.1016/j.procir.2015.12.065.
- Byrne, G.; Damm, O.; Monostori, L.; Teti, R.; van Houten, F.; Wegener, K. et al. (2021): Towards high performance living manufacturing systems - A new convergence between biology and engineering. In: *CIRP Journal of Manufacturing Science and Technology* 34, S. 6–21. DOI: 10.1016/j.cirpj.2020.10.009.
- Christopher, Martin; Peck, Helen (2004): Building the Resilient Supply Chain. In: *International Journal of Logistics Management* 15, S. 1–13. DOI: 10.1108/09574090410700275.
- Di Orio, Giovanni; Cândido, Gonçalo; Barata, José (2015): The Adapter module: A building block for Self-Learning Production Systems. In: *Robotics and Computer-Integrated Manufacturing* 36, S. 25–35. DOI: 10.1016/j.rcim.2014.12.007.
- Dilts, D. M.; Boyd, N. P.; Whorms, H. H. (1991): The evolution of control architectures for automated manufacturing systems. In: *Journal of Manufacturing Systems* 10 (1), S. 79–93. DOI: 10.1016/0278-6125(91)90049-8.
- DIN ISO 31000:2018-10, Risikomanagement – Leitlinien (ISO_31000:2018).
- Ehrhardt, Jonas M.; Hoffmann, Christoph T. (2020): The Digital Shadow: Developing a universal model for the automated optimization of cyber-physical production systems based on real-time data. In: *Procedia CIRP* 93, S. 304–310. DOI: 10.1016/j.procir.2020.03.069.
- Elbasheer, Mohaiad; Longo, Francesco; Mirabelli, Giovanni; Padovano, Antonio; Solina, Vittorio; Talarico, Simone (2022): Integrated Prescriptive Maintenance and Production Planning: a Machine Learning Approach for the Development of an Autonomous Decision Support Agent. In: *IFAC-PapersOnLine* 55 (10), S. 2605–2610. DOI: 10.1016/j.ifacol.2022.10.102.
- Frick, Nicholas; Metternich, Joachim (2022): The Digital Value Stream Twin. In: *Systems* 10 (4), S. 102. DOI: 10.3390/systems10040102.

Greis, Noel P.; Nogueira, Monica L.; Rohde, Wolfgang (2022): Towards Learning-Enabled Digital Twin with Augmented Reality for Resilient Production Scheduling. In: *IFAC-PapersOnLine* 55 (10), S. 1912–1917. DOI: 10.1016/j.ifacol.2022.09.678.

Hofmann, Constantin; Krahe, Carmen; Stricker, Nicole; Lanza, Gisela (2020): Autonomous production control for matrix production based on deep Q-learning. In: *Procedia CIRP* 88, S. 25–30. DOI: 10.1016/j.procir.2020.05.005.

Hosseini, Seyedmohsen; Al Khaled, Abdullah; Sarder, M. D. (2016): A general framework for assessing system resilience using Bayesian networks: A case study of sulfuric acid manufacturer. In: *Journal of Manufacturing Systems* 41, S. 211–227. DOI: 10.1016/j.jmsy.2016.09.006.

Johann-Dietrich Wörner; Christoph M. Schmidt (2022): Sicherheit, Resilienz und Nachhaltigkeit.

Klaas, Alexander; Streit, Daniel; Schilling, Markus; Dangelmaier, Wilhelm (2013): Proactive Self-Adaptation of a Flexible Simulation Based Control System Using Forecasting. In: *IFAC Proceedings Volumes* 46 (7), S. 99–104. DOI: 10.3182/20130522-3-BR-4036.00095.

Kuhnle, Andreas (2020): Adaptive order dispatching based on reinforcement learning: application in a complex job shop in the semiconductor industry. Dissertation.

Kuhnle, Andreas; Röhrig, Nicole; Lanza, Gisela (2019a): Autonomous order dispatching in the semiconductor industry using reinforcement learning. In: *Procedia CIRP* 79, S. 391–396. DOI: 10.1016/j.procir.2019.02.101.

Kuhnle, Andreas; Schäfer, Louis; Stricker, Nicole; Lanza, Gisela (2019b): Design, Implementation and Evaluation of Reinforcement Learning for an Adaptive Order Dispatching in Job Shop Manufacturing Systems. In: *Procedia CIRP* 81, S. 234–239. DOI: 10.1016/j.procir.2019.03.041.

Leng, Jiewu; Sha, Weinan; Lin, Zisheng; Jing, Jianbo; Liu, Qiang; Xin, Chen (2022): Blockchained smart contract pyramid-driven multi-agent autonomous process control for resilient individualised manufacturing towards Industry 5.0. In: *International Journal of Production Research* 61 (13), S. 4302–4321. DOI: 10.1080/00207543.2022.2089929.

Leng, Jiewu; Zhong, Yuanwei; Lin, Zisheng; Xu, Kailin; Mourtzis, Dimitris; Zhou, Xueliang et al. (2023): Towards resilience in Industry 5.0: A decentralized autonomous manufacturing paradigm. In: *Journal of Manufacturing Systems* 71, S. 95–114. DOI: 10.1016/j.jmsy.2023.08.023.

Liu, Youshan; Fan, Jiaxin; Zhao, Linlin; Shen, Weiming; Zhang, Chunjiang (2023): Integration of deep reinforcement learning and multi-agent system for dynamic scheduling of re-entrant hybrid flow shop considering worker fatigue and skill levels. In: *Robotics and Computer-Integrated Manufacturing* 84, S. 102605. DOI: 10.1016/j.rcim.2023.102605.

Michael Grieves (2016): Origins of the Digital Twin Concept: Unpublished. Online verfügbar unter https://www.researchgate.net/publication/307509727_Origins_of_the_Digital_Twin_Concept.

Möhring, H.-C.; Wiederkehr, P.; Erkorkmaz, K.; Kakimoto, Y. (2020): Self-optimizing machining systems. In: *CIRP Annals* 69 (2), S. 740–763. DOI: 10.1016/j.cirp.2020.05.007.

Morariu, Cristina; Morariu, Octavian; Răileanu, Silviu; Borangiu, Theodor (2020): Machine learning for predictive scheduling and resource allocation in large scale manufacturing systems. In: *Computers in Industry* 120, S. 103244. DOI: 10.1016/j.compind.2020.103244.

Mukherjee, Avik; Glatt, Moritz; Mustafa, Waleed; Kloft, Marius; Aurich, Jan C. (2022): Designing Resilient Manufacturing Systems using Cross Domain Application of Machine Learning Resilience. In: *Procedia CIRP* 115, S. 83–88. DOI: 10.1016/j.procir.2022.10.054.

Nasteski, Vladimir (2017): An overview of the supervised machine learning methods. In: *HORIZONS* 4, S. 51–62. DOI: 10.20544/horizons.b.04.1.17.p05.

Neto, Anis Assad; Carrijo, Bruna Sprea; Romanzini Brock, João Guilherme; Deschamps, Fernando; Lima, Edson Pinheiro de (2021): Digital twin-driven decision support system for opportunistic preventive maintenance scheduling in manufacturing. In: *Procedia Manufacturing* 55, S. 439–446. DOI: 10.1016/j.promfg.2021.10.060.

Paraschos, P. D.; Xanthopoulos, A. S.; Koulinas, G. K.; Koulouriotis, D. E. (2022): Machine learning integrated design and operation management for resilient circular manufacturing systems. In: *COMPUTERS & INDUSTRIAL ENGINEERING* 167, S. 107971. DOI: 10.1016/j.cie.2022.107971.

Parveen, Sultana; Ullah, Hafiz (2011): REVIEW ON JOB-SHOP AND FLOW-SHOP SCHEDULING USING. In: *J. mech. eng.* 41 (2), S. 130–146. DOI: 10.3329/jme.v41i2.7508.

Peukert, Sina; Hörger, Moritz; Lanza, Gisela (2023): Fostering robustness in production networks in an increasingly disruption-prone world. In: *CIRP Journal of Manufacturing Science and Technology* 41, S. 413–429. DOI: 10.1016/j.cirpj.2023.01.002.

Qin, Zhaojun; Lu, Yuqian (2021): Self-organizing manufacturing network: A paradigm towards smart manufacturing in mass personalization. In: *Journal of Manufacturing Systems* 60, S. 35–47. DOI: 10.1016/j.jmsy.2021.04.016.

Schwendemann, Sebastian; Amjad, Zubair; Sikora, Axel (2021): A survey of machine-learning techniques for condition monitoring and predictive maintenance of bearings in grinding machines. In: *Computers in Industry* 125, S. 103380. DOI: 10.1016/j.compind.2020.103380.

Sheth, Ananya; Kusiak, Andrew (2022): Resiliency of Smart Manufacturing Enterprises via Information Integration. In: *Journal of Industrial Information Integration* 28, S. 100370. DOI: 10.1016/j.jii.2022.100370.

Singh, N. (1993): Design of cellular manufacturing systems: An invited review. In: *European Journal of Operational Research* 69 (3), S. 284–291. DOI: 10.1016/0377-2217(93)90016-G.

Steinmeyer, Maximilian; Metternich, Joachim (2023): Resilienz aus der Wertstromperspektive 118 (9), S. 605–609. DOI: 10.1515/zwf-2023-1123.

Stricker, Nicole; Kuhnle, Andreas; Sturm, Roland; Friess, Simon (2018): Reinforcement learning for adaptive order dispatching in the semiconductor industry. In: *CIRP Annals* 67 (1), S. 511–514. DOI: 10.1016/j.cirp.2018.04.041.

Sturm, Roland (2006): Modellbasiertes Verfahren zur Online-Leistungsbewertung von automatisierten Transportsystemen in der Halbleiterfertigung. Unter Mitarbeit von Universität Stuttgart.

Zhang, W. J.; van Luttervelt, C. A. (2011): Toward a resilient manufacturing system. In: *CIRP Annals* 60 (1), S. 469–472. DOI: 10.1016/j.cirp.2011.03.041.

Zonta, Tiago; Da Costa, Cristiano André; Zeiser, Felipe A.; Oliveira Ramos, Gabriel de; Kunst, Rafael; Da Rosa Righi, Rodrigo (2022): A predictive maintenance model for optimizing production schedule using deep neural networks. In: *Journal of Manufacturing Systems* 62, S. 450–462. DOI: 10.1016/j.jmsy.2021.12.013.